

# 概率论与数理统计第20讲

## 第六章 参数估计

在实际问题中, 当所研究的总体分布类型已知, 但分布中含有一个或多个未知参数时, 如何根据样本来估计未知参数, 这就是参数估计问题.



参数估计问题分为点估计问题与区间估计问题两类. 所谓点估计就是用某一个函数值作为总体未知参数的估计量; 区间估计就是对于未知参数给出一个范围, 并且在一定可靠度下使这个范围包含未知参数的真值.



# 参数估计问题的一般提法

设有一个总体 $X$ , 总体的分布函数为 $F(x, \theta)$ , 其中 $\theta$ 为未知参数( $\theta$ 可以是向量). 现从该总体中随机地抽样, 得到一个样本

$$X_1, X_2, \dots, X_n,$$

再依据该样本对参数 $\theta$ 作出估计, 或估计参数 $\theta$ 的某已知函数 $g(\theta)$ .



# § 6.1 点估计问题概述

## 一, 点估计的概念

设  $X_1, X_2, \dots, X_n$  是取自总体  $X$  的一个样本,  $x_1, x_2, \dots, x_n$  是相应的一个样本值.  $\theta$  是总体分布中的未知参数, 为估计未知参数  $\theta$ , 需构造一个适当的统计量

$$\hat{\theta}(X_1, X_2, \dots, X_n),$$

然后用其观察值  $\hat{\theta}(x_1, x_2, \dots, x_n)$

来估计  $\theta$  的值. 称  $\hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  的**估计量**, 称  $\hat{\theta}(x_1, x_2, \dots, x_n)$  为  $\theta$  的**估计值**, 它们统称为**点估计**, 简称为**估计**, 并简记为  $\hat{\theta}$



**注：**估计量  $\hat{\theta}(X_1, X_2, \dots, X_n)$  是一个随机变量，是样本的函数，即是一个统计量，对于不同的样本值， $\theta$  的估计值  $\hat{\theta}$  一般是不同的。



## 二, 评价估计量的标准

估计量的评价一般有三条标准:

- (1) 无偏性;
- (2) 有效性;
- (3) 相合性(一致性)





# 1. 无偏性

**定义 1** 设  $\hat{\theta}(X_1, \dots, X_n)$  是未知参数  $\theta$  的估计量, 若

$$E(\hat{\theta}) = \theta,$$

则称  $\hat{\theta}$  为  $\theta$  的无偏估计量.



**定理 1** 设  $X_1, \dots, X_n$  为取自总体  $X$  的样本, 总体  $X$  的均值为  $\mu$ , 方差为  $\sigma^2$ , 则

(1) 样本均值  $\bar{X}$  是  $\mu$  的无偏估计量;

(2) 样本方差  $S^2$  是  $\sigma^2$  的无偏估计量;

(3) 样本二阶中心矩  $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $\sigma^2$  的有偏估计量(但却是**渐近无偏估计量**).



## 2. 有效性

**定义 2** 设  $\hat{\theta}_1 = \hat{\theta}_1(X_1, \dots, X_n)$  和  $\hat{\theta}_2 = \hat{\theta}_2(X_1, \dots, X_n)$  都是参数  $\theta$  的无偏估计量, 若  $D(\hat{\theta}_1) < D(\hat{\theta}_2)$ , 则称  $\hat{\theta}_1$  较  $\hat{\theta}_2$  **有效**.



**注：**最小方差无偏估计的定义如下：  
设  $X_1, \dots, X_n$  是取自总体  $X$  的一个样本，  
 $\hat{\theta}(X_1, \dots, X_n)$  是未知参数  $\theta$  的一个估计量，若  
 $\hat{\theta}$  满足：

①  $E(\hat{\theta}) = \theta$ ，即  $\hat{\theta}$  为  $\theta$  的无偏估计；

②  $D(\hat{\theta}) \leq D(\hat{\theta}^*)$ ， $\hat{\theta}^*$  是  $\theta$  的任一无偏估计。

则称  $\hat{\theta}$  为  $\theta$  的**最小方差无偏估计**(也称**最佳无偏估计**)。



### 3. 相合性(一致性)

**定义 3** 设  $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$  为未知参数  $\theta$  的估计量, 若  $\hat{\theta}$  依概率收敛于  $\theta$ , 即对任意  $\varepsilon > 0$ , 有

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1,$$

或

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| \geq \varepsilon\} = 0,$$

则称  $\hat{\theta}$  为  $\theta$  的**相合估计量(一致估计量)**.



## § 6.2 点估计的常用方法

# 一, 矩估计法

根据大数定理, 可用样本矩估计总体矩.

一般地, 记总体  $k$  阶矩  $\mu_k = E(X^k)$ ;

样本  $k$  阶矩  $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ ;

总体  $k$  阶中心矩  $\nu_k = E[X - E(X)]^k$ ;

样本  $k$  阶中心矩  $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$ .



**定义1** 用相应的样本矩去估计总体矩的方法就称为**矩估计法**. 用矩估计法确定的估计量称为**矩估计量**. 相应的估计值称为**矩估计值**. 矩估计量与矩估计值统称为**矩估计**.





## 求矩估计的方法:

设总体 $X$ 的分布函数 $F(x; \theta_1, \dots, \theta_k)$ 中有 $k$ 个未知参数 $\theta_1, \dots, \theta_k$ , 则

(1) 求总体 $X$ 的前 $k$ 阶矩 $\mu_1, \dots, \mu_k$ , 一般都是这 $k$ 个未知参数的函数, 记为

$$\mu_i = g_i(\theta_1, \dots, \theta_k), \quad i=1, 2, \dots, k \quad (2.1)$$

(2) 从(1)中解得 $\theta_j = h_j(\mu_1, \dots, \mu_k), j=1, \dots, k$

• (3) 再用 $\mu_i$ 的估计量 $A_i$ 代替上式中的 $\mu_i$ , 即可得 $\theta_j(j=1, 2, \dots, k)$ 的矩估计量:

$$\hat{\theta}_j = h_j(A_1, \dots, A_k), \quad j=1, 2, \dots, k.$$



例3 设总体  $X$  的均值  $\mu$  和方差  $\sigma^2 (> 0)$  都存在,  $\mu, \sigma^2$  未知.  $X_1, \dots, X_n$  是来自  $X$  的样本, 试求  $\mu, \sigma^2$  的矩估计量.

解  $\mu_1 = E(X) = \mu$

$$\mu_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2$$

解得

$$\mu = \mu_1$$

$$\sigma^2 = \mu_2 - \mu_1^2$$

于是  $\mu, \sigma^2$  的矩估计量为  $\hat{\mu} = A_1 = \bar{X}$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$



## 二, 最大似然估计法

**引例** 某同学与一位猎人一起去打猎, 一只野兔从前方窜过, 只听一声枪响, 野兔应声倒下, 试猜测是谁打中的?

由于只发一枪便打中, 而猎人命中的概率大于这位同学命中的概率, 故一般会猜测这一枪是猎人射中的.



**1. 最大似然估计法的思想:** 在已经得到实验结果的情况下, 应该寻找使这个结果出现的可能性最大的那个  $\theta$  值作为  $\theta$  的估计  $\hat{\theta}$

**注:** 最大似然估计法首先由德国数学家高斯于1821年提出, 英国统计学家费歇于1922年重新发现并作了进一步的研究. 下面分别就离散型总体和连续型总体情形作具体讨论.



**(1) 离散型总体** 的情形: 设总体 $X$ 的概率分布为  $P\{X=x\}=p(x,\theta)$ , ( $\theta$ 为未知参数). 如果 $X_1, X_2, \dots, X_n$ 是取自总体 $X$ 的样本, 样本的观察值为 $x_1, x_2, \dots, x_n$ , 则样本的联合分布律

$$P\{X_1 = x_1, \dots, X_n = x_n\} = \prod_{i=1}^n p(x_i, \theta),$$

在给·定观察值的情况下, 它是 $\theta$ 的函数, 记为

$$L(\theta) = L(x_1, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i, \theta),$$

称其为**似然函数**.



(2) 连续型总体 的情形: 设总体 $X$ 的概率密度为 $f(x, \theta)$ , 其中 $\theta$ 为未知参数, 此时定义似然函数

$$L(\theta) = L(x_1, \cdots, x_n; \theta) = \prod_{i=1}^n f(x_i, \theta).$$



似然函数  $L(\theta)$  的值的大小意味着该样本值出现的可能性的 大小，在已得到样本值  $x_1, x_2, \dots, x_n$  的情况下，则应该选择使  $L(\theta)$  达到最大值的那个  $\theta$  作为  $\theta$  的估计  $\hat{\theta}$ . 这种求点估计的方法称为**最大似然估计法**.



**定义 2** 若对任意给定的样本值  $x_1, x_2, \dots, x_n$ , 存在

$$\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n),$$

使 
$$L(\hat{\theta}) = \max_{\theta} L(\theta),$$

则称  $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$  为  $\theta$  的**最大似然估计值**. 称相应的统计量  $\hat{\theta}(X_1, X_2, \dots, X_n)$  为  $\theta$  的**最大似然估计量**. 它们统称为  $\theta$  的**最大似然估计(MLE)**.





## 2. 求最大似然估计的一般方法

求未知参数 $\theta$ 的最大似然估计问题, 归结为求似然函数 $L(\theta)$ 的最大值点的问题. 当似然函数关于未知参数可微时, 可利用微分学中求最大值的方法求之.



## 主要步骤:

- (1) 写出似然函数  $L(\theta)=L(x_1, x_2, \dots, x_n; \theta)$ ;
- (2) 令  $\frac{dL(\theta)}{d\theta} = 0$  或  $\frac{d \ln L(\theta)}{d\theta} = 0$ , 求出驻点;
- (3) 判断并求出最大值点, 在最大值点的表达式中, 用样本值代入就得参数的最大似然估计值.



**注:** 因函数 $\ln L$ 是 $L$ 的单调增加函数, 且函数 $\ln L(\theta)$ 与函数 $L(\theta)$ 有相同的极值点, 故常转化为求函数 $\ln L(\theta)$ 的最大值点较方便.

**注:** ①当似然函数关于未知函数不可微时, 只能按最大似然估计法的基本思想求出最大值点.

②上述方法易推广至多个未知参数的情形.



**例5** 设 $X \sim b(1, p)$ ,  $X_1, X_2, \dots, X_n$ 是取自总体 $X$ 的一个样本. 试求参数 $p$ 的最大似然估计.

**解** 设 $x_1, x_2, \dots, x_n$ 是相应于样本 $X_1, X_2, \dots, X_n$ 的一个样本值,  $X$ 的分布律为

$$P\{X=x\} = p^x(1-p)^{1-x}, \quad x=0,1.$$

故似然函数为

$$L(p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i}$$

$$\ln L(p) = \sum_{i=1}^n [x_i \ln p + (1-x_i) \ln(1-p)]$$



$$\ln L(p) = \sum_{i=1}^n [x_i \ln p + (1 - x_i) \ln(1 - p)]$$

$$= \ln p \sum_{i=1}^n x_i + \ln(1 - p) \left( n - \sum_{i=1}^n x_i \right)$$

$$\text{令 } \frac{d \ln L(p)}{d p} = \frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1 - p} \left( n - \sum_{i=1}^n x_i \right) = 0$$

$$\frac{n}{p} \bar{x} - \frac{n}{1 - p} (1 - \bar{x}) = 0$$

$$(1 - p) \bar{x} - p(1 - \bar{x}) = 0 \Rightarrow \bar{x} - p = 0, \hat{p} = \bar{x}$$



**例6** 设总体 $X$ 服从 $[0, \theta]$ 上的均匀分布,  $\theta$ 未知.  $X_1, \dots, X_n$ 为 $X$ 的样本,  $x_1, \dots, x_n$ 为样本值. 试求 $\theta$ 的最大似然估计.

**解** 似然函数为

$$L(\theta) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_1, \dots, x_n \leq \theta \\ 0, & \text{其它,} \end{cases}$$

显然无法从 $L'(\theta)=0$ 得到最大似然估计. 我们考虑直接按最大似然法的基本思想来确定.



$$L(\theta) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_1, \dots, x_n \leq \theta \\ 0, & \text{其它,} \end{cases}$$

欲使 $L(\theta)$ 最大,  $\theta$ 应尽量小但又不能太小, 它必须同时满足

$$\theta \geq x_i, \quad i=1, \dots, n,$$

否则 $L(\theta)=0$ , 而0不可能是 $L(\theta)$ 的最大值.

因此

$$\hat{\theta} = \max \{x_1, \dots, x_n\} \text{ 和 } \hat{\theta} = \max \{X_1, \dots, X_n\}$$

是最大似然估计值和估计量.



**例7** 设总体 $X$ 服从指数分布, 概率密度为

$$f(x, \lambda) = \begin{cases} \lambda e^{-\lambda x}, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (\lambda > 0)$$

$\lambda$ 是未知参数.  $x_1, x_2, \dots, x_n$ 是来自总体 $X$ 的一个样本观察值, 求参数 $\lambda$ 的最大似然估计值.





## 解 似然函数

$$L(x_1, \dots, x_n; \lambda) = \begin{cases} \prod_{i=1}^n \lambda e^{-\lambda x_i}, & x_i > 0 \\ 0, & \text{其它} \end{cases}$$

则 $L$ 的最大值点一定是

$$L_1(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i}$$

的最大值点.



$$L_1(x_1, \dots, x_n; \lambda) = \prod_{i=1}^n \lambda e^{-\lambda x_i}$$

对其取对数得

$$\ln L_1(x_1, \dots, x_n; \lambda) = \sum_{i=1}^n (\ln \lambda - \lambda x_i)$$

由

$$\frac{d L_1(x_1, \dots, x_n; \lambda)}{d \lambda} = \frac{n}{\lambda} - n\bar{x} = 0$$

得

$$\hat{\lambda} = \frac{1}{\bar{x}}$$



**例8** 设 $x_1, x_2, \dots, x_n$ 是正态总体 $N(\mu, \sigma^2)$ 的样本观察值, 其中 $\mu, \sigma^2$ 是未知参数, 试求 $\mu$ 和 $\sigma^2$ 的最大似然估计值.

**解** 似然函数

$$L(x_1, \dots, x_n; \mu, \sigma^2) = \prod_{i=1}^n \left( \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} \right)$$

$$\ln L(x_1, \dots, x_n; \mu, \sigma^2) =$$

$$= -n \ln \sqrt{2\pi} - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$



$$\begin{aligned}\ln L(x_1, \dots, x_n; \mu, \sigma^2) &= \\ &= -n \ln \sqrt{2\pi} - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\end{aligned}$$

由

$$\left\{ \begin{aligned} \frac{\partial L}{\partial \mu} &= \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \frac{\partial L}{\partial \sigma^2} &= \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2\sigma^2} = 0 \end{aligned} \right.$$



$$\begin{cases} \frac{\partial L}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \frac{\partial L}{\partial \sigma^2} = \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2\sigma^2} = 0 \end{cases}$$

得 $\mu$ 和 $\sigma^2$ 的最大似然估计值为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

最大似然估计量为

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$



# 作业 习题6-2 第161页开始 第1,2,6题

