

生成对抗网络 (GAN) 及其在各种学科中的应用回顾 从医学到遥感

ANKAN DASH, JUNYI Ye, and Guiling Wang,新泽西理工学院计算机科学系

美国科技

我们研究了生成对抗网络 (GAN)、它在多个领域的流行变体和应用。GAN 结合了两个使用零和博弈论相互竞争的神经网络,使它们能够创建更清晰和离散输出。GAN 可用于执行图像处理、视频生成和预测以及其他计算机视觉应用。

GAN 还可用于各种与科学相关的活动,包括蛋白质工程、天文数据处理、遥感图像去雾和晶体结构合成。GAN 取得进展的其他值得注意的领域包括金融、营销、时装设计、体育和音乐。因此,在本文中,我们全面概述了GAN 在各种学科中的应用。我们首先介绍支持 GAN 的理论、GAN 变体以及评估 GAN 的指标。

然后我们介绍了 GAN 及其变体如何应用于十二个领域,从 STEM 领域,如天文学和生物学,到商业领域,如营销和金融,再到艺术,如音乐。因此,其他领域的研究人员可能会掌握 GAN 的工作原理并将其应用到自己的研究中。据我们所知,本文对 GAN 在不同领域的应用进行了最全面的调查。

CCS 概念: 一般和参考→调查和概述; 计算方法→计算机视觉;神经网络; 计算理论→机器学习理论。

附加关键词和短语:深度学习、生成对抗网络、计算机视觉、时间序列、应用

ACM 参考格式:

Ankan Dash,Junyi Ye and Guiling Wang. 2021. 生成对抗网络 (GAN) 及其在各种学科中的应用 从医学到遥感的回顾。1月1日(2021年10月), 41页。 <https://doi.org/https://doi.org/>

1 简介

生成对抗网络 [48]或 GAN 属于生成模型 [44] 家族。生成模型尝试从训练集中学习概率密度函数,然后生成从相同分布中抽取的新样本。GAN 通过使两个神经网络(生成器和鉴别器)相互对抗来生成类似于真实数据的新合成数据。生成器尝试捕获真实的数据分布以生成新样本。另一方面,鉴别器通常是一个二元分类器,它试图尽可能精确地区分真实和假生成的样本。

在过去的几年中,GAN 取得了长足的进步。由于硬件的进步,我们现在可以训练更深、更复杂的生成器和判别器神经网络架构,并增加模型容量。

与其他类型的生成模型相比,GAN 具有许多明显的优势。不像玻尔兹曼机[62],

作者地址:Ankan Dash,ad892@njit.edu;叶俊义,jy394@njit.edu; Guiling Wang, guiling.wang@njit.edu,新泽西理工学院计算机科学系, 323 Dr Martin Luther King Jr Blvd, Newark, NJ, USA, 07102。

允许为个人或课堂使用制作全部或部分作品的数字或硬拷贝,但不收取任何费用,前提是拷贝不是为了营利或商业利益而制作或分发的,并且拷贝带有本通知和首页上的完整引文。必须尊重 ACM 以外的其他人拥有的本作品组件的版权。允许以信用摘录。要以其他方式复制或重新发布、在服务器上发布或重新分发到列表,需要事先获得特定许可和/或收费。从 permissions@acm.org 请求权限。

© 2021 计算机协会。
提交给 ACM 的手稿

提交给 ACM 的手稿

GAN 不需要蒙特卡洛近似来训练, GAN 使用反向传播并且不需要马尔可夫链。

近年来, GAN 获得了很大的关注, 并已广泛应用于各个学科, 并且可以使用 GAN 的领域列表迅速扩大。GAN 可用于数据生成和增强 ([78]、[134])、图像到图像转换 ([70]、[197])、图像超分辨率 ([93]、[73]) 等等。

正是这种多才多艺的性质, 使得 GAN 可以应用于完全不相关的领域, 例如医学和天文学。

由于 GAN 的广受欢迎和重要性, 已经有一些关于 GAN 的调查和评论。然而, 过去的大多数论文都集中在两个不同的方面: 首先, 描述 GAN 及其随时间的增长, 其次, 讨论 GAN 在图像处理和计算机视觉应用中的使用 ([47]、[3]、[135]、[51]、[1])。

因此, 关注的焦点不再是描述 GAN 在广泛学科中的应用。因此, 我们将在这篇同类文章中对 GAN 进行全面回顾。我们将研究 GAN 和一些最广泛使用的 GAN 模型和变体, 以及一些评估指标, GAN 在各种 12 个领域 (包括图像和视频相关任务、医疗和保健、生物学、天文学) 中的应用、遥感、材料科学、金融、营销、时尚、体育和音乐), GAN 的挑战和局限, 以及 GAN 的未来方向。

这篇论文的一些主要贡献如下:

- 描述 GAN 在工程、科学、社会科学、商业、艺术、音乐和体育领域的广泛应用。据我们所知, 这是第一篇涵盖 GAN 在如此不同领域中的应用的评论论文。这篇综述将帮助不同背景的研究人员理解 GAN 的操作并发现它们的广泛应用。

- GAN 的评估包括定性和定量方法。本调查全面介绍了用于评估 GAN 在计算机视觉和时间序列数据分析中的性能的性能的定量指标。我们在时间序列数据中包含了 GAN 应用的评估指标, 这些指标在其他 GAN 调查论文中没有讨论。据我们所知, 这是第一篇介绍 GAN 时间序列数据评估指标的调查论文。

我们将文章的其余部分组织如下: 第 2 节介绍了 GAN 的基本工作, 以及最常用的 GAN 变体及其描述。第 3 节总结了一些常用的 GAN 评估指标。第 4 节描述了 GAN 在各个领域的广泛应用。我们还在每个小节的末尾提供了一个表格, 总结了应用领域和使用的相应 GAN 模型。第 5 节讨论了在 GAN 训练过程中遇到的一些困难和挑战。除此之外, 我们还简要总结了 GAN 的未来发展方向。第 6 节提供结论性意见。

2 GAN、GAN 变体和扩展

在本节中, 我们将描述 GAN, 最常见的 GAN 模型和扩展。在对 GAN 理论的描述之后, 我们介绍了 12 种 GAN 变体, 它们作为许多其他 GAN 模型的基础或构建块。

有很多关于 GAN 的文章, 其中很多都有命名为 GAN, 它们是具有特定名称的模型, 通常包含 “GAN” 这个词。我们专注于十二个特定的 GAN 变体。通过阅读这 12 个 GAN 变体, 读者将更好地了解 GAN 的核心方面, 这将有助于他们浏览其他 GAN 模型。

提交给 ACM 的手稿

2.1 GAN 基础

生成对抗网络由 Ian Goodfellow 等人开发 [48]在 2014 年。GAN 属于生成模型类[44]。GAN 基于最小-最大、零和博弈论。为此,GAN 由两个神经网络组成:一个是生成器,另一个是判别器。生成器的目标是学习生成虚假的样本分布来欺骗鉴别器,而鉴别器的目标是学习区分生成器生成的真实分布和虚假分布。

2.1.1 网络架构和学习。由生成器和鉴别器组成的 GAN 的一般架构如图 1 所示。生成器 (G) 将一些随机噪声向量 z 作为输入,然后尝试使用表示为 $G(z)$ 的噪声向量生成图像)。然后将生成的图像传递给鉴别器,并根据鉴别器的输出更新生成器的参数。鉴别器 (D) 是一个二元分类器,它同时查看生成器生成的真实样本和虚假样本,并尝试确定哪些是真实的,哪些是虚假的。给定样本图像 x ,判别器模拟图像是假的还是真实的概率。然后将概率作为反馈传递回生成器。

随着时间的推移,生成器和鉴别器模型中的每一个都试图通过相互竞争来相互竞争,这就是生成对抗网络的“对抗”一词的来源,并且优化基于极小极大博弈问题。在训练期间,生成器和判别器的参数都使用反向传播进行更新,生成器的最终目标是能够生成逼真的图像,而判别器在检测生成的假图像和真实图像方面越来越好。

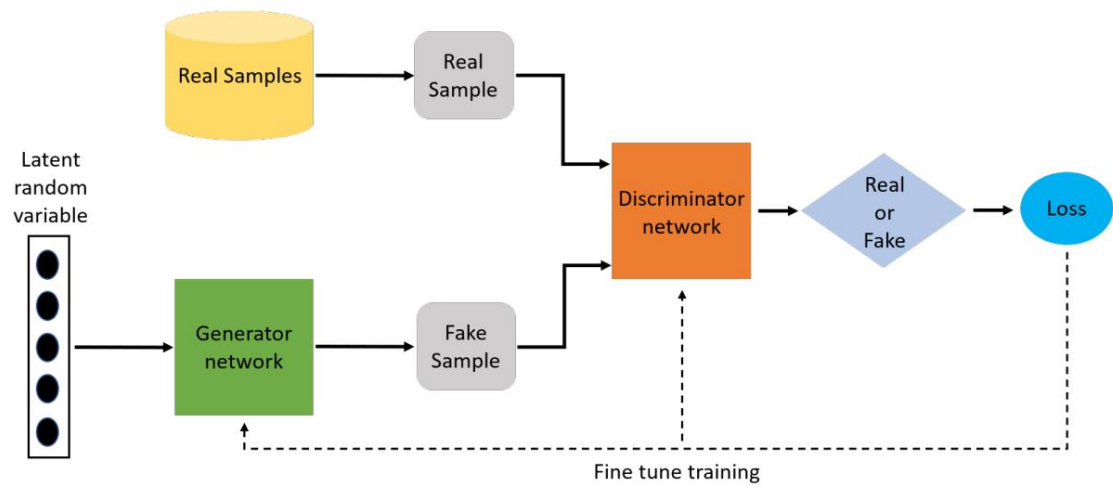


图 1. 基本 GAN 架构

GAN 使用 Goodfellow 等人引入的 Minimax 损失函数。当他们第一次引入 GAN 时,生成器尝试最小化以下函数,而鉴别器尝试最大化它。Minimax 损失为,

$$V(D, G) = E [V(x)] + E [1 - V(G(z))]. \tag{1}$$

这里,是所有真实数据样本的期望值, $\hat{p}_D(x)$ 是判别器的概率估计,如果是实数, $\hat{p}_D(x)$ 是给定随机噪声向量作为输入的生成器的输出, $\hat{p}_D(x)$ 是鉴别器的输出。如果生成的假样本是真实的,则概率估计是生成器的所有随机输入的期望值。

2.2 条件生成对抗网络 (cGAN)

条件生成对抗网络 [118]或 cGAN 是 GAN 用于条件样本生成的扩展。这可以控制正在生成的数据的模式。cGANs 使用其他形式的一些额外信息,通过将这些额外信息与输入连接并将其输入,例如类标签或生成器 G 和鉴别器 D。Minimax 目标函数可以修改如下所示,

$$V(D, G) = E [D(x, y)] + E [D(1 - G(z, y))]$$

(2)

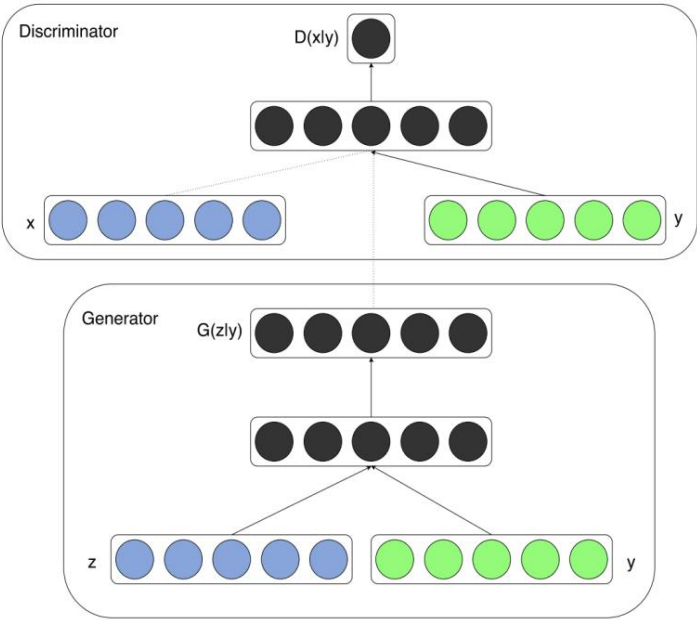


图 2. cGAN 架构[118]

2.3 Wasserstein BY (WGAN)

WGAN[7] 的作者介绍了一种新算法,它可以替代传统的 GAN 训练。他们表明他们的新算法提高了模型学习的稳定性并防止了模式崩溃等问题。对于批评模型,WGAN 使用权重裁剪,确保权重值 (模型参数)保持在预定义的范围。作者发现 Jensen-Shannon 散度对于测量距离不相交部分的分布。因此,他们使用了使用地球概念的 Wasserstein 距离提交给 ACM 的手稿

移动者 (EM)距离来测量生成的数据分布和真实数据分布之间的距离,而训练模型试图保持 One-Lipschitz 连续性[53]。

真实数据分布和生成数据分布的 EM 或 Wasserstein 距离为

$$W(\mu, \nu) = \inf_{\gamma \in \Pi(\mu, \nu)} \int \|x - y\| d\gamma(x, y) \tag{3}$$

其中 $\Pi(\mu, \nu)$ 表示所有联合分布 (μ, ν) 的集合,其边际分别为 μ 和 ν 。然而, Wasserstein 距离的方程非常棘手。因此,作者使用了 Kantorovich-Rubinstein 对偶性将 Wasserstein 距离近似为

$$W(\mu, \nu) = \sup_{f \in \text{Lip}_K} \int f(x) d\mu(x) - \int f(y) d\nu(y) \tag{4}$$

其中 Lip_K 表示一个参数化的函数族,对于某个 K ,它们都是 K -Lipschitz。判别器 D 的目标是优化这个表示近似 Wasserstein 距离的参数化函数。目标生成器 G 的目的是最小化上述 Wasserstein 距离方程,使得生成的数据分布为尽可能接近真实分布。整体 WGAN 目标函数为

$$W(\mu, \nu) = \sup_{f \in \text{Lip}_K} \int f(x) d\mu(x) - \int f(y) d\nu(y) \tag{5}$$

或者

$$W(\mu, \nu) = \sup_{f \in \text{Lip}_K} \int f(x) d\mu(x) - \int f(y) d\nu(y) \tag{6}$$

尽管 WGAN 提高了训练稳定性并缓解了模式崩溃等问题,但仍强制执行 Lipschitz 约束是一项具有挑战性的任务。WGAN-GP[53]提出了一种通过使用梯度来裁剪权重的替代方案。惩罚批评者相对于其输入的梯度范数。

2.4 使用深度卷积生成对抗网络的无监督表示学习

(DCGAN)

拉德福德等人[134]介绍了深度卷积生成对抗网络或 DCGAN。正如名字建议 DCGAN 将深度卷积神经网络用于生成器和判别器模型。这最初的 GAN 架构仅使用多层感知器或 MLP,但由于 CNN 在图像方面比 MLP 更好, DCGAN 的作者在生成器 G 和鉴别器 D 神经网络架构中使用了 CNN。三键 DCGANs 神经网络架构的特点如下:

- 首先,对于图 3 所示的生成器,卷积被替换为转置卷积,因此生成器的每一层的表示逐渐变大,因为它是从低维潜在的向量到高维图像上。用跨步卷积替换任何池化层 (鉴别器) 和分数步幅卷积 (生成器)。
- 其次,在生成器和判别器中使用批量标准化。
- 第三,在生成器中对除使用Tanh 的输出之外的所有层使用ReLU 激活。使用 LeakyReLU 在所有层的鉴别器中激活。
- 第四,使用 Adam 优化器而不是 SGD 与动量。

以上所有修改都使得 DCGAN 能够实现稳定的训练。 DCGAN 很重要,因为作者证明了通过强制执行某些约束,我们可以开发复杂的高质量生成器。作者还对 vanilla GAN 架构进行了其他一些修改。




图 3. DCGAN 生成器架构[134]

2.5 GAN 的逐步发展以提高质量、稳定性和变化（ProGAN）

卡拉斯等人[78]介绍了一种新的训练方法,用于训练 GAN 以生成高分辨率图像。ProGAN 背后的想法是能够在训练过程中通过鉴别器和生成器网络的增量（逐渐）增长来合成高分辨率和高质量的图像。ProGAN通过逐渐将生成器从较低分辨率的图像训练到那些更高分辨率的图像,使生成器更容易生成更高分辨率的图像（参见图4.）。也就是说,在渐进式 GAN 中,生成器的第一层会生成分辨率非常低的图像,随后的层会添加细节。渐进式学习过程大大稳定了培训。




图 4. ProGAN 架构[78]

2.6 通过信息最大化生成对抗网络的可解释表示学习
(信息甘)

InfoGAN[19] 背后的主要动机是使 GAN 能够学习解开的表示,并以无监督的方式控制生成图像的属性或特征。要做到这一点,而不是只使用一个噪音
提交给 ACM 的手稿

向量作为输入作者将噪声向量分解为两部分,首先是传统的噪声向量和第二个是新的“潜在代码向量”。此代码对输出图像具有可预测的影响。目标函数为 InfoGAN[19]给出为,

$$I(z, \theta) = I(z, \theta) - I(z, \theta)$$

(7)

其中是正则化参数, θ 是潜在代码和潜在代码之间的互信息发电机输出 $I(z, \theta)$ 。这个想法是最大化潜在代码和生成器之间的互信息输出。这鼓励潜在代码尽可能多地包含真实的重要和相关特征数据分布。但是,根据需要进行显式计算互信息 $I(z, \theta)$ 是不切实际的后验 $p(\theta|z)$, 因此 $I(z, \theta)$ 的下界是近似的。这可以通过定义一个辅助分布 $q(\theta|z)$ 到近似 $p(\theta|z)$ 。因此,目标函数的最终形式由此给出互信息的下界近似:

$$I(z, \theta) = I(z, \theta) - I(z; \theta)$$

(8)

在哪里 $I(z; \theta)$ 是 $I(z, \theta)$ 的下限 $I(z, \theta)$ 。如果我们将上述等式与原始 GAN 目标进行比较函数我们意识到这个框架是通过在原始 GAN 中添加一个正则化项来实现的目标函数。

2.7 StackGAN :使用堆叠生成对抗网络的文本到照片般逼真的图像合成 (堆栈甘)

StackGAN[189]如图5 所示,将文本描述作为输入,然后使用合成高质量图像给定的文本描述。作者提出 StackGAN 基于文本生成 256×256 逼真的图像说明。为了生成照片般逼真的图像 StackGAN 使用草图细化过程,StackGAN 分解通过使用 Stacked Generative Adversarial Networks 将难题转化为更易于管理的子问题。这 Stage-I GAN通过绘制对象的原始形状和颜色来创建 Stage-I 低分辨率图像给定文字描述。 Stage-II GAN使用Stage-I 生成具有照片般逼真细节的高分辨率图像结果和文本描述作为输入。

为了能够做到这一点,StackGAN 架构由以下组件组成: (a) 输入可变长度文本描述被转换成一个固定长度的向量嵌入。(b) 调节增强。(c) 第一阶段发电机:生成 (128x128) 图像 (d) 第一阶段鉴别器 (e) 第二阶段生成器 :生成 (256x256) 图像。(f) 第二阶段鉴别器

可变长度文本描述首先被转换为向量嵌入,该向量嵌入被非线性转换为生成条件潜变量作为生成器的输入。填充嵌入的潜在空间随机生成的填充是论文中使用的一种技巧,可以使数据流形更加连续,从而更多有利于后期训练。他们还添加了输入高斯分布的 Kullback-Leibler 散度和高斯分布作为生成器训练输出的正则化项,使数据流形更多持续和培训友好。

Stage I GAN 使用以下目标函数:

$$\mathcal{L}_G = E_{(z, \theta) \sim p(z, \theta)} [\log p(\theta | z, \theta)] + E_{(z, \theta) \sim q(z, \theta)} [\log (1 - p(\theta | z, \theta))]$$

(9)

提交给 ACM 的手稿

这 L_1 或像素距离损失由下式给出

$$L_1() = E \left[\sum_{i=1}^N |f_i - g_i| \right]$$

(14)

最终的损失函数由下式给出

$$\arg \min_{\theta} L(\theta) + \lambda L_1(\theta)$$

(15)

其中是加权超参数系数。 Pix2PixHD[170]是 Pix2Pix 算法的改进版本。
Pix2PixHD 的主要目标是生成高分辨率图像并执行语义操作。去做这个
作者介绍了多尺度生成器和判别器,并结合了 cGAN 和特征匹配损失
功能。训练集由成对的对图图像组成(,其中 是语义标签图,是
对应的自然图像。 cGAN 损失函数由下式给出,

$$E(s, x) [\log (s, x)] + E_s [\log (1 - (s, s))]$$

(16)

Discriminator 的第 i 层特征提取器作为loss L_i , f_i () (从输入到 的第 th 层) 。特征匹配
() 是 (谁)给的

$$L_i = E(s, x) \sum_{h=1}^H \frac{1}{H} (f_i(s, x) - f_i(s, s))^2$$

(17)

其中 H 是总层数,表示每层中的元素数。的目标函数
pix2pixHD 由下式给出

$$\sum_{i=1}^H L_{GAN}(f_i(s, x)) + \sum_{i=1}^H L_i(s, s)$$

(18)




图 6. 使用 pix2pix 将边缘映射到彩色图像[70]。 D,判别器,学习区分假货 (Generator-generated) 和实际的 (边缘,照片)元组。 G,生成器,学习如何欺骗鉴别器。与无条件 GAN 相比,生成器和鉴别器都查看输入边缘图。

2.9 使用循环一致对抗网络 (CycleGAN)的非配对图像到图像转换

pix2pix 的一个致命缺陷是它需要配对图像进行训练,因此不能用于未配对的数据
没有输入和输出对。 CycleGAN[197]通过引入循环一致性损失来解决这个问题
尝试在经过一个循环的平移和反向平移后保留原始图像。匹配的图像对没有
在这个公式中的培训需要更长的时间。 CycleGAN 使用两个生成器和两个判别器。发电机
G 用于将图像从 X 域转换到 Y 域。另一方面,生成器 F 将图像从 Y 转换为
 x_0 (: \rightarrow , : \rightarrow)。鉴别器 区别于 ()和鉴别器

区分

提交给 ACM 的手稿

从()。对抗性损失应用于两个映射函数。对于映射函数： \rightarrow 及其鉴别器，目标函数由下式给出

$$\begin{aligned} \text{LGAN}(\cdot, \cdot, \cdot) = & E_{\text{数据}(\cdot)} [\log(\cdot)] \\ & + E_{\text{数据}(\cdot)} [\log(1 - (\cdot))] \end{aligned} \tag{19}$$

作者认为,仅对抗性损失并不能保证学习到的函数可以映射一个个体输入到所需的输出,因为它使模型不受约束。因此,作者使用了循环一致性损失使得学习的映射是循环一致的。它基于以下假设,如果您将图像从一个域到另一个域并通过按顺序通过两个生成器再次返回,你应该得到一些东西类似于您输入的内容。前向循环一致性表示为 $\rightarrow(\cdot) \rightarrow ((\cdot)) \approx$ 和后向循环一致性表示为 $\rightarrow(\cdot) \rightarrow ((\cdot)) \approx$ 。循环一致性损失由下式给出

$$\begin{aligned} \text{Lcyc}(\cdot, \cdot) = & E_{\text{数据}(\cdot)} [\| \cdot(\cdot) - \cdot \|_1] \\ & + E_{\text{数据}(\cdot)} [\| \cdot(\cdot) - \cdot \|_1] \end{aligned} \tag{20}$$

最终的完整目标由下式给出

$$\begin{aligned} L(\cdot, \cdot, \cdot, \cdot) = & \text{LGAN}(\cdot, \cdot, \cdot) \\ & + \text{LGAN}(\cdot, \cdot, \cdot) \\ & + \text{Lcyc}(\cdot, \cdot), \end{aligned} \tag{21}$$

其中控制两个目标的相对重要性。

$$\begin{aligned} \cdot, \cdot = & \text{参数最小值}, \text{最大限度}, L(\cdot, \cdot, \cdot, \cdot) \end{aligned} \tag{22}$$




图 7. CycleGAN [197] (a) 两个生成器映射函数： \rightarrow 和： \rightarrow 。(二) 前向循环一致性损失： $\rightarrow(\cdot) \rightarrow ((\cdot)) \approx$ 和 (c) 后向循环一致性损失： $\rightarrow(\cdot) \rightarrow ((\cdot)) \approx$

2.10 生成对抗网络的基于样式的生成器架构 (StyleGAN)

StyleGAN[80] 的主要目标是生成高质量、高分辨率的人脸图像,这些图像在本质上和提供对生成的合成图像的样式的控制。StyleGAN 是 ProGAN[78]模型的扩展,使用渐进式增长方法通过增量合成高分辨率和高质量图像在训练过程中(逐渐)增长鉴别器和生成器网络。重要的是要注意提交给 ACM 的手稿

StyleGAN 的变化只影响生成器网络,这意味着它们只影响生成过程。与传统 GAN 相同的鉴别器和损失函数没有改变。升级后的生成器包括对 ProGAN 生成器的几个附加功能,如图8 所示。如下所述:

- Baseline Progressive GAN:作者使用 Progressive GAN(ProGAN[78])作为他们继承网络架构和一些超参数的基线。·双线性上/下采样: ProGAN 模型使用最近邻上/下采样,但作者 StyleGAN 的生成器和判别器都使用了双线性采样层。·映射网络、样式网络和AdaIN:它不是直接将噪声向量馈入生成器,而是通过映射网络得到中间噪声向量。映射网络 (\cdot) 的输出随后通过学习仿射变换 (A),然后通过自适应实例归一化 [68]或 AdaIN 模块进入合成网络。在图中 “A”代表学习仿射变换。 AdaIN 模块传递噪声向量,在卷积层之后被合并到生成器模型的每个块中。 AdaIN 模块首先将特征图的输出转换为标准高斯,然后添加样式向量作为偏置项。映射网络是标准的深度神经网络,由 8 个全连接层组成,合成网络由 18 层组成。

·去除传统输入:大多数模型,包括 ProGAN,利用随机输入来生成生成器的初始图像。然而,StyleGAN 作者发现图像特征由 AdaIN 控制。

因此,他们通过消除传统的输入层并开始图像合成来简化架构
具有学习的常数张量。

- 添加噪声输入:在评估非线性之前,在每次卷积之后添加高斯噪声。在图7 中。“B”是每个通道应用于噪声输入的学习缩放因子。·混合正则化:作者还引入了一种新颖的正则化方法来减少相邻样式的相关性,并对生成的图像进行更细粒度的控制。混合正则化不是只传递一个潜在向量,通过映射网络作为输入并获得一个向量,作为输出,而是通过映射向量传递两个潜在向量1和2 并获得两个向量1和2。 o_1 和 o_2 对于每次迭代都是完全随机的,这种技术可以防止网络假设彼此相邻的样式相关。

2.11 循环GAN (RGAN)和循环条件GAN (RCGAN)

除了生成合成图像,GAN 还可以生成序列数据[38, 119]。时间序列数据的生成模型不是对原始特征空间中的数据分布进行建模,而是捕获给定历史数据的条件分布($| 1: -1$)。循环 GAN 和传统 GAN 在架构上的主要区别在于,我们在生成器和判别器中都用循环神经网络 (RNN) 替换了 DNN/CNN。在这里,RNNGAN 的变体,例如生成器和判别器都和一些循环神经网络,它们捕捉和表示数据中的时间依赖性,能够有效地生成逼真的时间序列合成数据。

在图9 中,我们说明了 RGAN 和 RCGAN 的架构。生成器 RNN 在每个时间步采用随机噪声来生成合成序列。然后,Discriminator RNN 作为分类器来区分

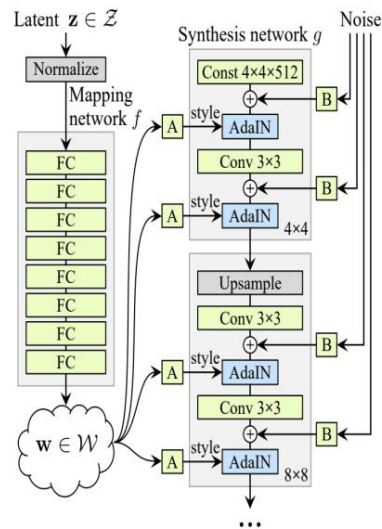


图 8. StyleGAN 生成器[80]


输入是真的还是假的。条件输入连接到发生器的顺序输入和判别器,如果它是一个 RCGAN。与 GAN 类似,RCGAN 中的 Discriminator 最小化了生成的数据和真实的数据。鉴别器损失公式如下。

$$D(z, w) = - \mathbb{E}_z \left[\log D(z, w) \right] \tag{23}$$

其中 $(z \in \mathbb{R}^{\times})$ 和 $(w \in \{1, 0\})$ 是具有序列长度的判别器的输入和输出和特征尺寸。 w 是一个向量,1 表示真实序列,0 表示合成序列。 (\cdot) 是平均交叉熵功能和 (\cdot) 是判别器中的 RNN。发电机损失公式如下。

$$G(z, w) = \mathbb{E}_w \left[\log G(z, w) \right] \tag{24}$$

这里, w 是一个随机噪声向量 $w \in \mathbb{R}^{\times}$ 。在 RCGAN 的情况下,Generator 和鉴别器还在每个时间步连接条件信息。



如图。9. RCGAN 和 RCGAN [38]

2.12 时间序列GAN (TimeGAN)

最近,提出了一种新的 GAN 框架,称为时间序列 GAN (TimeGAN) [183],它保留了时间动态。除了最小化传统 GAN 学习过程中的无监督对抗性损失外,(1) TimeGAN 引入了使用原始输入作为监督的逐步监督损失,明确鼓励模型捕获数据中的逐步条件分布。(2) TimeGAN 引入自编码器网络来学习映射来自特征空间和嵌入/潜在空间,这降低了对抗性学习空间的维数。(3) 为了最小化监督损失,部署了自动编码器和生成器的联合训练,这迫使模型以嵌入为条件来学习时间关系。TimeGAN 框架不仅捕获了每个时间步的特征分布,但也捕获了特征在时间上的复杂时间动态。

TimeGAN由四个重要部分组成,embedding function、recovery function、Generator和Discriminator在图10中。首先,自动编码器(前两部分)从输入序列中学习潜在表示。然后,对抗模型(后两部分)在潜在空间上联合训练以生成具有时间的合成序列通过最小化无监督损失和监督损失来实现动力学。

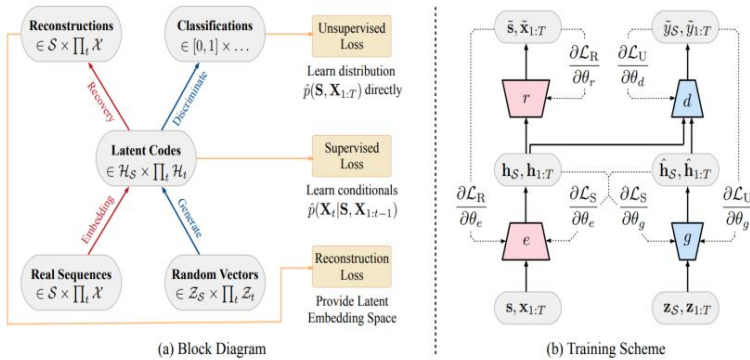


图 10.(a) TimeGAN 中四个关键组件的框图。(b) 训练方案:实线和虚线代表正向分别是传播路径和反向传播路径。 [183]

表 1. 常见 GAN 模型的应用

常见的 GAN 变体和扩展	应用领域
DCGAN [134]	图像生成
cGAN [118]	半监督条件图像生成
InfoGAN [19]	可解释和解开表示的无监督学习
StackGAN[189]	基于文本输入的图像生成
Pix2Pix[70]	图像到图像的翻译
CycleGAN[197]	未配对的图像到图像的转换
StyleGAN [80]	本质上多样化的分辨率面部图像生成
RGAN,RCGAN [38]	合成医学时间序列数据生成
时间GAN [183]	真实的时间序列数据生成

3 GAN 评估指标

GAN 训练最困难的方面之一是评估它们的性能,或确定模型的性能近似于数据分布。在理论和应用方面取得了重大进展,现在可用的 GAN 变体数量。然而,在评估 GAN 上投入的精力相对较少,并且定量评估方法仍存在差距。在本节中,我们将介绍相关且流行的指标用于评估 GAN 的性能。

(1) Inception Score (IS) : IS由Salimans等人提出[141]它采用了预训练的 InceptionNet[154]

在 ImageNet[29] 上训练以捕获生成样本的所需属性。平均 Kullback–Leibler 或样本的条件标签分布($p(y|x)$)与边缘分布之间的KL 散度[76]

($p(y|x)$)由所有样品计算得出,采用 IS 测量。IS 的目标是评估一组特征的两个特征

生成的图像:图像质量 (评估图像中是否包含有意义的对象)和图像

多样性。因此 IS 倾向于 ($p(y|x)$) 但 ($p(y)$) 的熵很高。IS 可以表示为:

$$\exp \left(\mathbb{E}_x \left[\text{KL} \left(p(y|x) \parallel p(y) \right) \right] \right) \tag{25}$$

较高的 IS 表明生成模型能够生成高质量的样本,这些样本也是多样化的。

(2) Modified Inception Score (m-IS):在其原始形式中,Inception Score 分配产生低的模型

熵类条件分布($p(y|x)$)具有较高分数的整体生成数据。然而,这是可取的

在一个样本类别中具有多样性。为了描述这种多样性,Gurumurthy 等人 [55]提出了一个

inception-score 的修改版本,其中包含交叉熵样式得分- ($p(y|x)$) 日志 ($p(y)$) 日志 ($p(y|x)$)

的样本。修改后的 IS

可以定义为,

$$\exp \left(\mathbb{E}_x \left[\text{KL} \left(p(y|x) \parallel p(y) \right) \right] \right) \tag{26}$$

m-IS 是按类计算的,然后在所有类中取平均值。m-IS 可以被认为

评估类内样本多样性和样本质量。

(3) Mode Score(MS): Che等人[16]引入的MODE score是 IS 的改进版本,可解决

IS 的主要缺陷之一:它忽略了地面实况标签的先验分布。与 IS 相比,MS 可以

测量真实分布和生成分布之间的差异。

$$\exp \left(\mathbb{E}_x \left[\text{KL} \left(p(y|x) \parallel p(y) \right) \right] \right) \tag{27}$$

在哪里 $p(y)$ 是根据训练数据计算的标签的经验分布。根据作者的

评估,MODE 分数成功衡量了生成模型的两个重要方面,即多样性

和视觉质量。

(4) Frechet Inception Distance (FID):由 Heusel 等人提出[61], Frechet Inception Distance 分数决定了为真实图像和生成图像

计算的特征向量的差异程度。特定层

FID 分数使用InceptionNet[154]模型来捕获和嵌入输入图像的特征。这

通过计算两者的均值和协方差,嵌入被总结为多元高斯

生成数据和真实数据。这两个高斯人之间的 Fréchet 距离 (或 Wasserstein-2 距离)

然后用于量化生成样本的质量。

$$\left(\mu_1, \Sigma_1 \right) = \left(\mu_2, \Sigma_2 \right) = - \frac{1}{2} \left(\text{Tr} \left(\Sigma_1^{-1} \Sigma_2 \right) + \text{Tr} \left(\Sigma_2^{-1} \Sigma_1 \right) - 2 \right) \tag{28}$$

在哪里, Σ 和(μ, Σ)表示生成和真实的经验均值和经验协方差数据分布分别。合成 (模型生成)和真实数据分布之间的距离更小由较低的 FID 表示。

(5)图像质量度量:下面我们介绍一些常用的图像质量评估度量。

将 GAN 生成的数据与真实数据进行比较。

(a)结构相似度指数测量 (SSIM)[173]是一种量化两幅图像之间相似度的方法。

SSIM 试图对图像结构信息的感知变化进行建模。SSIM 值在 -1 和 1,其中值 1 表示完全相似。多尺度 SSIM 或 MS-SSIM[174]是多尺度版本与单一的 SSIM 相比,它在结合图像分辨率和查看条件方面具有更大的灵活性尺度方法。MS-SSIM 的范围在 0 (低相似度)和 1 (高相似度)之间。

(b)峰值信噪比或 PSNR 将生成图像的质量与其对应的真实图像的质量进行比较

通过测量两个单色图像的峰值信噪比来获得图像。例如评估条件 GAN 或 cGAN [118]较高的 PSNR (以 db 为单位)表明生成的图像质量更好。

(c)清晰度差异 (SD) 表示生成图像和真实图像之间的清晰度差异。这

值越大,图像之间的清晰度差异越小,生成的图像越接近图像是真实的图像。

(6)时间序列/序列输入的评估指标:评估生成合成序列的质量

数据非常具有挑战性。例如,重症监护病房 (ICU) 信号对于非医疗输出而言看起来是完全随机的 [38]。研究人员评估合成序列数据的质量,主要集中在

以下三个不同的方面。(1)多样性 合成数据应该从相同的分布中生成真实数据。(2)保真度 合成数据应与真实数据无法区分。(3)可用性 合成数据应该足以用作训练/测试数据集。 [183]

(a) t-SNE 和 PCA [183] 都是常用的可视化工具,用于分析原始和合成

序列数据集。他们在时间维度上展平数据集,以便可以将数据集绘制在二维平面。他们测量生成样本的分布与原始样本的分布有多接近在二维空间中。

(b)判别分数[183] 评估二元分类器区分真实数据的难度

(原始)数据集和假 (生成)数据集。如果合成的,分类器很难分类数据和原始数据来自相同的分布。

(c)最大平均差异 (MMD) [38, 49]学习真实数据的分布。最大平均值

已经提出了差异方法来区分合成数据和真实数据是否来自通过计算真实样本和合成样本之间统计量的平方差来获得相同的分布()。无偏可以表示如下,其中函数之间的内部产生是替换为核函数。

$$\sigma^2 = \frac{1}{(-1)} \sum_{i=1}^n \sum_{j \neq i}^n (x_i, x_j) - \frac{2}{(-1)} \sum_{i=1}^n \sum_{j=1}^n (x_i, x_j) + \frac{1}{(-1)} \sum_{i=1}^n \sum_{j \neq i}^n (x_i, x_j) \tag{29}$$

适合时间序列数据的核函数至关重要。作者将时间序列作为向量进行比较,并选择径向基函数 (RBF)作为核函数,即 $(x_i, x_j) = (-1)^{\frac{\|x_i - x_j\|^2}{2\sigma^2}}$ 。

为了选择合适的内核带宽,MMD 检验的功效的 t 统计量的估计量

两个分布之间 $b = \frac{1}{\sqrt{2}}$ 被最大化。作者在训练期间拆分了一个验证集以调整参数。结果表明,通过可视化[38]评估的质量与质量密切相关。

(d)地球移动距离 (EMD) [163, 176]是衡量两个概率分布之间的距离超过一个区域。它描述了必须移动多少概率质量才能转换表示历史分布并且是生成的分布。EMD 定义为

$$d(\mu, \nu) = \inf_{\gamma \in \Pi(\mu, \nu)} \sum_{(x, y) \in \gamma} \|x - y\| \tag{30}$$

其中 $\Pi(\mu, \nu)$ 表示所有带边界的联合概率分布的集合和。

(e)自相关函数 (ACF) 分数[176]描述了历史和历史之间的相关系数生成的时间序列。让 $\{x_t\}_{t=1}^T$ 表示历史对数百分比变化系列和 $\{y_t\}_{t=1}^T$ 表示生成的日志百分比变化路径的长度 $\ell(\cdot)$ 。自相关是用时滞计算的和系列 $\ell(\cdot)$ 并测量滞后时间序列与序列本身的相关性

$$\rho(k) = \frac{\text{cov}(x_t, y_{t+k})}{\sqrt{\text{var}(x_t) \text{var}(y_{t+k})}} \tag{31}$$

ACF() 分数是针对函数计算的: $\rho(k)$ 为

$$\rho(k) := \frac{1}{T-k} \sum_{t=1}^{T-k} (\ell(x_t) - \bar{\ell}) (\ell(y_{t+k}) - \bar{\ell}) \tag{32}$$

其中 $\rho: [-1, 1] \rightarrow [-1, 1]$ 表示 $\rho(k)$ 。

(f) Leverage Effect Score [176]提供了历史和生成的时间依赖性的比较。这滞后的杠杆效应是使用滞后的、平方对数百分比变化的相关性来衡量的,以及日志百分比会自行更改。

$$\ell(\cdot) = \frac{1}{2} \sum_{t=1}^T (\ell(x_t) - \bar{\ell})^2 \tag{33}$$

杠杆效应得分由下式定义

$$\ell(\cdot) = \frac{1}{2} \sum_{t=1}^T (\ell(x_t) - \bar{\ell})^2 \tag{34}$$

其中 $\rho: [-1, 1] \rightarrow [-1, 1]$ 表示 $\rho(k)$ 。

4 GAN 应用

GAN 是迄今为止使用最广泛的生成模型,它们对于生成逼真的合成数据样本。在本节中,我们将介绍生成对抗的广泛领域网络 (GAN)正在被应用。具体来说,我们将介绍 GAN 在图像处理、视频生成中的使用与预测、医学与保健、生物学、天文学、遥感、材料科学、金融、时尚设计、运动和音乐。

提交给 ACM 的手稿

表 2. 相关和流行的 GAN 评估指标总结

定量指标	描述测量数据上
初始分数 (IS) [141]	的条件标签分布和边际标签分布之间的 KL 散度。
修改后的初始分数 (m-IS) [55]	结合交叉熵风格分数以促进样本类别内的多样性。
众数 (MS) [16]	改进了 IS 的版本,并考虑了地面实况标签的先验分布。
Frechet 起始距离 (FID) [61]	评估拟合嵌入特征空间的数据的多元高斯之间的 Fréchet 距离或 Wasserstein-2 距离。
结构相似性指数测量(SSIM[173])、峰值信噪比 (PSNR)、多尺度 SSIM (MS SSIM[174])和锐度差 (SD)	评估和评估生成图像的质量。
最大平均差异 (MMD[49, 119]),地球移动距离 (EMD [163, 176]),DY 公制 [176], ACF 得分[176],杠杆效应得分[176]	评估生成的序列数据的质量。

4.1 图像处理

GAN 在涉及特定图像处理相关任务时非常多产,例如图像超分辨率、图像编辑、高分辨率人脸生成、人脸属性操作等等。

·图像超分辨率:图像超分辨率是指将低分辨率图像转换为高分辨率图像的过程。 SRGAN[93]是第一个能够为 4 倍放大因子推断照片逼真的自然图像的图像超分辨率框架。还开发了其他几个超分辨率框架 ([73]、 [172])以产生更好的结果。最近开发的 Best-Buddy GANs[101]与之前的工作 ([198]、 [168])一起用于单图像超分辨率 (SISR)任务。

·图像编辑:图像编辑涉及删除或修改图像的某些方面。例如,在恶劣天气或大雨期间拍摄的图像缺乏视觉质量,因此需要人工干预以消除降低图像质量的雨滴或灰尘颗粒等异常情况。 ID-CGAN[187] 的作者使用 GAN 来解决单幅图像去雨的问题。图像修改可能涉及修改或更改图像的某些方面,例如更改头发颜色、添加微笑等,这在([131], [199])中得到了证明。

·高分辨率人脸图像生成:高分辨率人脸图像生成是GAN 擅长的另一个图像处理领域。使用 GAN 的人脸生成和属性操作可以大致分为创建整个合成人脸、人脸特征或属性操作和人脸组件转型。

- 合成人脸生成:合成人脸生成是指创建现实生活中不存在的人脸的合成图像。上一节中描述的ProGAN[78]演示了生成逼真的人脸图像。从那时起,有几部作品使用 GAN 来生成面部图像 ([191]、 [192]) 。 StyleGAN[79]是Nvidia 研究人员于 2018 年 12 月推出的一种独特的生成对抗网络。StyleGAN 的主要目标是生成性质多样的高质量人脸图像。为了实现这一点,作者使用了诸如使用噪声映射之类的技术

网络、自适应实例归一化和类似于 ProGAN 的渐进式增长以产生非常高分辨率的图像。

- 人脸特征或属性操作:人脸属性操作包括人脸姿态和表情变换。 PosIX-GAN[12] 的作者训练他们的模型,在将任意姿势的人脸图像作为输入时,生成具有 9 种不同姿势变化的高质量人脸图像。 DECGAN[17]作者使用Double Encoder Conditional GAN来进行面部表情合成。表达式条件 GAN (ECGAN)[156]可以学习从一个图像域到另一个图像域的映射,并且作者能够通过条件属性标签控制特定的面部表情。
- 面部组件变换:面部组件变换涉及改变面部样式 (头发颜色和样式)或添加眼镜等配件。 DiscoGAN[86] 的作者能够改变头发颜色,StarGAN[22] 的作者能够执行多域图像翻译。 BeautyGAN[100]可用于将化妆风格从给定的参考化妆人脸图像转换为另一个非化妆人脸图像,同时保留人脸身份。 InfoGAN[19] 的作者训练他们的模型以无监督的方式学习解开的表示,并且可以修改面部组件,例如添加或移除眼镜和改变发型。 GAN 也可以应用于图像修复,其任务是重建图像中的缺失区域。在这方面, GAN 已被使用 ([182]、 [184])来执行任务。

表 3. 图像处理中的应用

图像处理应用	GAN 模型
图像超分辨率	SRGAN [93]、TSRGAN [73]、ESRGAN [172]、最佳 BuddyGAN [101]、GMGAN [198]、PESR [168]
图像编辑和修改	ID-CGAN [187]、IcGAN [131]
合成人脸生成	ProGAN [78]、StyleGAN [80]
人脸特征或属性操作	PosIX-BY [12]、DECGAN [17]、ECGAN [156]
人脸组件变换	DiscoGAN [86]、StarGAN [22]、BeautyGAN [100]、InfoGAN [19]

4.2 视频生成与预测

使用 GAN 合成视频可分为三大类。(a) 无条件视频生成 (b)

条件视频生成 (c) 视频预测

4.2.1 无条件视频生成.对于无条件视频生成,GAN 模型的输出不以任何输入信号为条件.由于在训练阶段缺乏作为视频条件提供的任何信息,这些框架产生的输出视频通常质量低下。

VGAN[165] 的作者是第一个将 GAN 应用于视频生成的人.他们的 Generator 由两个CNN 网络组成,一个是 3D 时空卷积网络,用于捕捉前景中的运动物体,另一个是 2D 空间卷积模型,用于捕捉静态背景.来自生成器的两个独立输出被组合以创建生成的视频并馈送到鉴别器,以确定它是真实的还是假的。

时间生成对抗网络 (TGAN)[140]可以从未标记的视频数据集中学习表示并生成新视频。 TGAN 生成器由两个子生成器组成,其中一个 是时间生成器和 提交给 ACM 的手稿

另一个是图像生成器。时间生成器将单个潜在变量作为输入,并生成一组潜在变量,每个潜在变量对应一个视频帧。图像生成器从一组潜在变量中创建视频。鉴别器由三维卷积层组成。TGAN 使用 WGAN 提供稳定的训练并满足 K-Lipschitz 约束。FTGAN[125]由两个 GAN 组成:FlowGAN 和 TextureGAN。

FlowGAN 网络处理运动,即添加光流以更有效地表示对象运动。TextureGAN 模型用于生成以先前 FlowGAN 结果为条件的纹理,以生成所需的帧。运动和内容分解生成对抗网络或 MoCoGAN[160]使用运动和内容分解表示来生成视频。MoCoGAN 由四个子网络组成:循环神经网络、图像生成器、图像鉴别器、视频鉴别器和视频鉴别器。Dual Video Discriminator GAN (DVD-GAN)[24]建立在 BigGAN[14] 架构上,是一种用于生成高质量帧的生成视频模型。DVD-GAN 采用循环神经网络 (RNN) 单元以及双鉴别器架构来处理空间和时间维度。

4.2.2 条件视频生成。在条件视频生成中,GAN 模型的输出取决于输入信号,例如文本、音频或语音。我们不考虑其他条件技术,例如图像到视频、语义映射到视频和视频到视频,因为这些可以被认为属于下面第 4.5.2 节中描述的视频预测类别。

对于文本到视频的合成,目标是根据一些条件文本生成视频。李等人[103]使用变分自动编码器 (VAE)[88]和生成对抗网络 (GAN)从文本生成视频。他们的模型由一个条件 gist 生成器 (条件 VAE)、一个视频生成器和一个视频鉴别器组成。初始图像/要点由条件要点生成器创建,它以编码文本为条件。此要点用作所需视频的图像、背景颜色和对象布局的一般表示。然后通过调节要点和文本输入,使用 cGAN 生成视频的内容和动作。Temporal GANs Conditioning on Captions (TGANs-C)[140]使用双向 LSTM 和基于 LSTM 的编码器来嵌入并获得输入文本的表示。然后将此输出表示与随机噪声向量连接,然后将其提供给生成器,这是一个 3D 反卷积网络,用于生成合成逼真的视频。该模型具有三个判别器:视频判别器区分真实视频和合成视频,并将视频与正确的字幕对齐,帧判别器确定每帧是真/假以及给定字幕的语义匹配/不匹配,运动判别器利用时间连续帧之间的一致性。巴拉吉等人。提出了文本过滤条件生成对抗网络 (TFGAN)[9]。TFGAN 引入了一种新颖的多尺度文本调节技术,其中从编码文本中提取文本特征并用于创建卷积过滤器。然后,卷积过滤器被输入到鉴别器网络中,以在 GAN 模型中学习良好的视频-文本关联。StoryGAN[102]基于顺序条件 GAN 框架,其任务是为给定的多句子段落中的每个句子生成图像序列。GAN 模型由()故事编码器、()基于循环神经网络 (RNN) 的上下文编码器、()图像生成器和()

一个图像鉴别器和一个故事鉴别器。BoGAN[18]在各个层次上保持视频与相应语言描述之间的语义匹配,并确保连续帧之间的连贯性。作者使用 LSTM 和基于 3D 卷积的编码器解码器架构根据输入文本从嵌入生成帧。提出了区域级语义对齐模块,以鼓励生成器在本地级别上利用视频和单词之间的语义对齐。为了保持帧级和视频级的一致性,使用了两个鉴别器。金等人[82]提出了文本到图像到视频的生成对抗网络

(TiVGAN) 用于基于文本的视频生成。关键思想是首先学习文本到单图像的生成,然后逐渐增加生成的图像数量,并重复直到达到所需的视频长度。

语音到视频合成涉及生成以音频/语音输入为条件的同步视频帧的任务。贾拉利法等人[71]使用 LSTM 和 CGAN 进行语音条件下的说话人脸生成。长短期记忆体

网络学习从音频特征中提取和预测面部标志位置。给定提取的一组地标,然后,cGAN 生成具有准确口型同步的同步面部图像。 Vougioukas 等人[167]使用GANs 生成说话头的视频。视频帧的生成取决于人的静止图像和包含语音的音频剪辑,不依赖于提取中间特征。他们的 GAN 架构使用 RNN 分别基于生成器、帧级和序列级鉴别器。解耦表示的想法 Zhou 等人[195]对此进行了探索。作者提出了分离式视听系统 (DAVS),它使用解开的视听表示,以创建高质量的说话人脸视频。

4.2.3 视频预测。视频预测是基于序列上下文预测未来视频帧的能力

以前的帧。正式的未来帧预测可以定义如下。设 $X \in \mathbb{R}^{w \times h \times l}$ 成为 帧中 视频帧序列 $X = (x_1, x_2, \dots, x_l)$, 其中 w, h, l 分别表示宽度、高度和帧数1, , 其中 分别为频道。目标是预测下一个帧序列 $Y = (y_1, y_2, \dots, y_{l+1})$ 使用输入 X 。

由于对视频中的内容和运动进行建模的复杂任务,视频预测是一项具有挑战性的任务 视频。在这方面,已经进行了几项研究来使用基于 GAN 的训练进行视频预测

([114],[164],[2],[66],[104],[166],[108])。马修等人[114]使用多尺度架构进行未来帧预测。这 网络使用对抗训练方法和图像梯度差异损失函数进行训练。 MCNet[164] 通过解开视频中的时间和空间动态来执行视频帧预测的任务。编码器 Decoder 卷积神经网络用于对视频内容进行建模,Convolutional-LSTM 用于建模

视频中的时间动态或运动。这样预测下一帧就像转换提取的 使用识别的运动特征将内容特征转换为下一帧内容。

FutureGAN[2]使用基于编码器-解码器的 GAN 模型来预测视频序列的未来帧。他们的 网络由所有编码器和解码器模块的时空 3D 卷积网络 (3D ConvNets)[159] 组成 捕获视频序列的空间和时间分量。有稳定的训练和预防问题 作者使用了带有梯度惩罚 (WGAN-GP)[52]损失的 Wasserstein GAN 和 逐渐增长的 GAN 或 ProGAN [78]已被证明可以生成高分辨率图像。 VPGAN[66]是 用于随机视频预测的基于 GAN 的框架。作者介绍了一种新的对抗推理模型, 一个动作控制保形映射网络,并为其模型使用循环一致性损失。作者还 将图像分割模型与其 GAN 框架相结合,以实现稳健和准确的帧预测。他们的 模型优于其他现有的随机视频预测方法。采用统一架构,Dual Motion GAN[104]试图联合解决未来框架和未来流预测问题。拟议的框架 将一系列帧作为输入,通过将未来帧预测与

未来基于流量的预测。为了实现这一点,Dual Motion GAN 采用概率运动编码器 (映射帧 到潜在空间),两个生成器 (一个未来框架生成器和一个未来流生成器),以及一个流估计器和 流动翘曲层。帧鉴别器和流鉴别器用于对未来的假帧和真实帧进行分类 和流动。巴塔查吉等人[13]通过使用多阶段 GAN 来解决未来帧预测的问题。捕捉 时间维度和处理帧间关系,作者提出了两个新的目标函数, 归一化互相关损失 (NCCL) 和成对对比发散损失 (PCDL)。多级 提交给 ACM 的手稿

GAN (MS-GAN)由 2 个 GAN 组成,以两个单独的分辨率生成帧,从而将 Stage-1 GAN 输出馈送到 Stage-2 GAN 以产生最终输出。权等人 [91]提出了一个基于 CycleGAN[197] 的新框架,称为 Retrospective CycleGAN,以预测未来的帧,这些帧在时间上更远,但比其他方法生成的帧相对更清晰。该框架由一个生成器和两个鉴别器组成。在训练期间,Generator 的任务是生成未来和过去的帧,并使用追溯周期约束来确保双向预测的一致性。帧鉴别器检测单个假帧,而序列鉴别器确定序列是否包含假帧。根据作者的说法,序列鉴别器在预测时间一致的未来帧中起着至关重要的作用。为了训练他们的模型,

使用了两个对抗性和两个重建损失函数的组合。

表 4. 视频生成和预测中的应用

视频生成和预测	GAN 模型
无条件视频生成	VGAN [165]、TGAN [140]、FTGAN [125]、MoCoGAN [160]、DVD-GAN [24]
条件视频生成	VAE-GAN [103]、TGANs-C [140]、TFGAN [9]、StoryGAN [102]、BoGAN [18]、TiVGAN [82]、LSTM 和cGAN [71]、基于 RNN 的BY [167]、TemporalGAN [195]
视频预测	多尺度GAN[114]、MCNet[164]、FutureGAN[2]、VPGAN[66]、双运动GAN[104]、MSGAN[13]、回顾循环GAN[91]

4.3 医疗保健

GAN 具有巨大的医学图像生成应用,可用于改善早期诊断、减少时间和支出。由于医学图像数据通常是有限的,GAN 可以通过进行图像到图像的转换、合成数据合成和医学图像超分辨率来用作数据增强技术。

GAN 在医疗和医疗保健中的一个主要应用是图像到图像的转换框架,即当需要多模态图像时,可以使用来自一种模态或域的图像在另一个域中生成图像。磁共振成像 (MRI)被认为是医学成像的黄金标准。不幸的是,对于植入金属的患者来说,这不是一个可行的选择,因为机器中的金属可能会干扰结果和患者的安全。MR-GAN[74]与 CycleGAN[197] 类似,用于将 2D 脑 CT 图像切片转换为 2D 脑 MR 图像切片。然而,与用于非配对图像到图像转换的 CycleGAN 不同,MR-GAN 使用配对和非配对数据进行训练,并结合了对抗性损失、双循环一致损失和体素损失。MCML-GANs[185]使用多通道多地标 (MCML)输入的方法从血管树、视盘和视杯图像的组合中合成彩色视网膜眼底图像。作者使用了基于 pix2pix[70]和 CycleGAN[197]模型框架的两个模型,并为 Generator 模型提出了几种不同的架构,并比较了它们的性能。赵等人[193]还提出了 Tub-GAN和 Tub-sGAN 图像到图像转换框架来生成视网膜和神经元图像。Armanious 等人[8]提出了 MedGAN 框架,通过将对抗性框架与非对抗性损失的新组合以及CasNet 和 ResNets[58]启发的架构的使用相结合,在医学图像生成领域将图像转换为图像转换。桑福特等人[142]使用 CycleGAN[197]转换对比 CT 图像

成非对比度图像。作者比较了在原始数据集上训练的 U-Net 与在原始数据的组合数据集上训练的 U-Net 的分割性能,并比较了合成的非对比图像。

DermGAN[45]用于生成具有皮肤状况的合成图像。该模型学习将包含预先指定的皮肤状况、其大小和位置以及潜在肤色的语义图转换为保留预先指定特征的逼真图像。DermGAN 生成器使用修改后的 U-Net[137],其中反卷积层被替换为最近邻调整大小层,然后是卷积层以减少棋盘效应。生成器和鉴别器经过训练以最小化特征匹配损失、最小-最大GAN 损失、整个图像的1个重建损失、病理区域的1个重建损失的组合。

除了解决图像到图像的转换问题之外,GAN 还广泛用于合成医学图像生成 ([116],[23],[25],[190])。科斯塔等人[25]为条件性视网膜血管网络合成的任务实现了对抗性自动编码器。比尔斯等人[10]应用 ProGAN 生成高分辨率和高质量的 512x512视网膜眼底图像和 256x256 多模态神经胶质瘤图像。张等人[190]使用 DCGAN[134]、WGAN[7]和边界平衡 GAN (BEGAN)[11]生成合成医学图像。他们使用生成的合成图像来扩充他们的数据集,以构建具有更高组织识别精度的模型。与未使用数据增强训练的基线模型相比,使用增强数据集进行的整体训练发现三个 GAN 模型的组织识别准确度有所提高。基于 WGAN[7] 的fNIRS-GANs[122]用于执行功能性近红外光谱 (fNIRS) 数据增强,以提高 fNIRS-脑机接口 (BCI) 的准确性。

使用数据增强,作者能够分别为 SVM 和神经网络模型实现更高的分类准确度,分别为 0.733 和 0.746,而没有数据增强训练的两种模型分类准确度均为 0.4。

为了通过生成匿名合成心电图 (ECG) 来防止数据泄露,Piacentino 等人[132]使用GAN。作者首先提出了一种新的通用程序,将原始数据转换为非常适合GAN 的图像。之后,建立、训练和评估了 GAN 设计。由于其简单性,作者选择使用辅助分类器生成对抗网络

(ACGAN)[124]来完成他们的预期任务。权等人[90]使用 GAN 来增强 mRNA 样本,以提高用于癌症检测的深度学习模型分类准确性。

通过将 GAN 生成的合成样本与原始数据集相结合,训练数据增加了 5 倍,作者能够将 F1 分数提高 39%。

图像重建和超分辨率对于获得用于诊断的高分辨率图像至关重要,因为诸如用于 MRI 的辐射量和其他图像采集技术会极大地影响所获得图像的质量。Chen等人提出的多层密集连接超分辨率网络,mDCSRN-GAN[20]。对生成器架构使用高效的 3D 神经网络设计来执行图像超分辨率。MedSRGAN[50]是用于医学图像的图像超分辨率 (SR) 框架。作者使用一种新颖的卷积神经网络,即残差全图注意力网络 (RWMAN) 作为生成器网络来处理低分辨率特征,然后执行上采样。对于鉴别器,作者使用了成对的输入低分辨率图像和生成的高分辨率图像,而不是仅仅生成单个高分辨率图像。山下等。al[179]评估了几种用于光学相干断层扫描 (OCT)[40]图像增强的超分辨率 GAN 模型 (SRCNN[32]、VDSR[83]、DRCN[84]和 ESRGAN[172])。作者发现 ESRGAN在 PSRN 和 SSIM 方面的性能最差,但从质量上讲,它是产生更清晰和高对比度图像的最佳方法。

表 5. 医疗保健中的应用

医疗保健应用	GAN 模型
多模态图像到图像的转换	pix2pix[70]、CycleGAN[197]、MR-GAN[74]、MCML GAN [185]、Tub-GAN 和 Tub-sGAN [193]、MedGAN [8]、DermGAN [45]
用于数据增强的图像生成	WGAN [7]、WGAN-GP [53]、DCGAN [134]、BEGAN [11]、ProGAN [78]、fNIRS-GAN [122]、阿甘 [124]
影像重建	SRCNN[32]、VDSR[83]、DRCN[84]、ESRGAN[172] mDCSRN-GAN [20]、MedSRGAN [50]

4.4 生物学

生物学是生成模型,尤其是 GAN 可以通过执行诸如蛋白质序列设计、数据增强和插补以及生物图像生成等任务产生巨大影响的领域。除此之外,GAN还可以用于结合亲和力预测。

蛋白质工程识别或开发具有某些优化特性的有用或有价值的蛋白质序列的过程。在蛋白质序列的深度生成模型的应用方面已经完成了几项工作,特别是 GAN 的使用 (Repecka 等人 [136]、Amimeur 等人 [4]和 Gupta 等人 [54])。GAN 可用于生成新的有效功能蛋白质序列并优化蛋白质序列以具有某些特定属性。ProteinGAN[136]可以直接从复杂的多维氨基酸序列空间中学习生成多种功能性蛋白质序列。作者专门使用 GAN 来生成功能性苹果酸脱氢酶。Aimeur 等人[4]开发了使用改进的 WGAN 来生成单链和双链抗体序列生成的 Antibody-GAN。他们的模型能够生成极其多样化的新文库,这些文库模仿体细胞超突变的人类曲目反应。作者还展示了使用迁移学习来使用他们的 GAN 模型来生成具有特定感兴趣属性的分子,例如 MHC II 类结合和特定的互补决定区域 (CDR) 特征。FBGAN[54]在反馈回路机制中使用 WGAN 架构和分析器,使用外部函数分析器优化合成基因序列以获得所需的特性。分析器是一个差分神经网络,它为来自生成器的采样序列分配一个分数。随着训练的进行,得分最低的生成序列被整个判别器训练集的得分高的生成序列所取代。Anand 等人使用了 GAN。[5]生成蛋白质结构,目的是在快速从头蛋白质设计中使用它们。

由于缺乏可用的生物样本或收集此类样本的成本, GAN 已被用于生物学中的数据增强和数据插补。最近的一些工作包括单细胞RNA-seq 的生成和分析 ([42], [113])。cscGAN[113]或条件单细胞生成对抗神经网络的作者使用 GAN 来生成真实的单细胞 RNA-seq 数据。王等人[171]提出了 GGAN,这是一个 GAN 框架,用于估算未测量基因的表达式。为此,他们使用条件 GAN 来利用表达数据中标志性基因和目标基因集之间的相关性。生成器将标志性基因表达作为输入并输出目标基因表达。这种方法利用了来自 1000 Genomes 等项目的表达数据中标志性基因和目标基因集之间的相关性。帕克等人[130]通过成功分析来自 AD 的 5xFAD 小鼠模型的 RNA-seq 数据,应用 GAN 来预测阿尔茨海默病 (AD) 的分子进展。具体来说,作者成功地将 WGAN+GP[52]应用于基因变异较少的批量 RNA-seq 数据

表达水平和较少数量的基因。scIGAN[178]是一个基于 GAN 的 scRNA-seq 插补框架。scIGAN 可以使用复杂的多细胞类型样本来学习非线性基因-基因相关性,并训练生成模型来生成已定义细胞类型的真实表达谱。

GAN 还可用于生成生物成像数据。CytoGAN[46]或细胞图像的生成建模,作者评估了几种 GAN 模型如 DCGAN[134]、LSGAN[111]和 WGAN[7] 用于细胞显微镜成像,特别是形态分析。通过他们的实验,他们发现 LSGAN是最稳定的,产生的图像质量比 DCGAN 和 WGAN 都高。GAN 也被用于生成逼真的电子显微镜图像 (Han 等人 [56])和生成通过荧光显微镜成像的细胞 (Oskin 等人 [127])。

预测结合亲和力是药物发现中的一项重要任务,尽管它仍然是一个挑战。通过预测药物与靶标之间的结合亲和力来帮助药物发现 Zhao et al.[194]设计使用了基于 GAN 的半监督方法。研究人员利用两个 GAN 从原始蛋白质和药物序列数据中学习表示,并利用卷积回归网络来预测亲和力。

表 6. 生物学中的应用

在生物学中的应用	GAN 模型
蛋白质工程	ProteinGAN [136]、Antibody-GAN [4]、FBGAN [54]、DCGAN [5]
数据增强和数据插补	cscGAN [113]、GGAN [171]、scIGAN [178]
用于生物图像合成的 GAN	CytoGAN [46]、SGAN [56]、DCGAN+Wasserstein 损失 [127]
结合亲和力预测	甘斯DTA [194]

4.5 天文学

随着大数据的出现,可供科学家进行数据驱动分析的公开数据量令人难以置信。每天,全球数百颗甚至数千颗卫星都会生成数 TB 的数据。凭借强大的计算资源,GAN 已进入天文学领域,并用于图像翻译、数据增强和光谱去噪等任务。

RadioGAN[43] 的作者将他们的 GAN 基于 Pix2Pix 模型,在两个不同的无线电测量数据集之间执行图像到图像的转换,以恢复扩展的通量密度。他们的模型在 20% 的误差范围内恢复了近一半源的扩展通量密度,并且在两次调查中学习了更复杂的源之间的关系,而不是简单地将它们与不同的合成光束进行卷积。其他几位作者也使用图像到图像的转换模型,例如 Pix2Pix、Pix2PixHD 来生成太阳图像 (Dash 等人、Park 等人 [129]、Kim 等人 [87]、Jeong 等人 [72]、Shin 等人 [144]等)。

除了图像到图像相关的任务外,GAN 还被广泛用于在天文学领域生成合成数据。史密斯等人[149]提出了 SGAN 以产生类似于哈勃太空望远镜拍摄的逼真的合成极深场 (XDF)图像。他们的 SGAN 模型具有与 DCGAN 相似的架构,可用于在天体物理学和其他领域生成合成图像。乌尔莫等人[161]使用 GAN生成宇宙学图像以绕过通常需要大量计算资源且非常昂贵的模拟。迪亚等人[31]表明 GAN 可以取代昂贵的模型驱动方法来生成天文图像。特别是,他们使用 ProGAN 和 Wasserstein 成本函数来生成逼真的星系图像。

基于 DCGAN 框架[134] 的ExoGAN[200]是第一个解决系外行星大气逆反演的深度学习方法。据作者称,ExoGAN 被发现比大光谱范围的标准检索速度快 300 倍。 ExoGAN 旨在与各种仪器和波长范围配合使用,无需任何额外培训。 Fussell 等人[41]探索了以链式方式使用 DCGAN[134]和StackGAN[189]生成高分辨率合成星系图像。

Spectra-GAN[177] 的作者设计了他们的光谱去噪算法。他们的算法是基于 CycleGAN 的,即它有两个生成器和两个鉴别器,除了 SpectraGAN 使用配对示例而不是未配对样本。该模型由三个损失函数组成:对抗性损失、循环一致损失和生成一致损失。

表 7. 天文学中的应用

天文学中的应用	GAN 模型
图像到图像的翻译	RadioGAN[43],pix2pix[70],pix2pixHD[170]
图像数据生成和增强	SGAN [149], DCGAN [134], ProGAN [78], ExoGAN[200]
图像去噪	Spectra-GAN [177]

4.6 遥感

将 GAN 用于遥感应用可以大致分为以下主要类别：

·数据生成或扩充： Lin 等人[105]提出了用于遥感数据增强的多层特征匹配生成对抗网络（MARTA GAN）。 MARTA GAN 基于 DCGAN[134]，然而 DCGAN 可以生成 64×64 分辨率的图像,而 MARTA GAN 可以生成 256×256 的遥感图像。为了生成高质量的远程图像样本,感知损失和特征匹配损失被用于模型训练。莫汉多斯等人[120]提出了 MSG-ProGAN 框架,该框架使用 10个具有不同分辨率的 Sentinel-2 卫星图像来生成逼真的多光谱图像以进行数据增强。为了帮助提高训练稳定性,作者将他们的模型基于 MSGGAN[77]、 ProGAN[78]模型并使用了 WGAN-GP[52]损失函数。因此,MSG-ProGAN 可以生成多光谱 256×256 卫星图像,而不是 RGB 图像。

·超分辨率： HRPGAN[151]使用受 PatchGAN 启发的架构将低分辨率遥感图像转换为高分辨率图像。作者没有使用批量归一化来保留遥感图像中地面物体的纹理和锐利边缘。此外,将 ReLU 激活替换为 SELU激活,以降低整体训练损失和稳定训练。此外,作者使用了一种新的损失函数,包括传统的对抗性损失、感知重建损失和正则化损失来训练他们的模型。 D-SRGAN[28]将低分辨率数字高程模型 (DEM) 转换为高分辨率 DEM。

D-SRGAN 基于 SRGAN[93]模型。对于训练,D-SRGAN 使用对抗性损失和内容损失的组合。

· Pan-Sharpening： Liu 等人[107]提出了 PSGAN 来解决图像全色锐化的任务,并使用不同的图像数据集和不同的生成器架构进行了几次实验。在低尺度和全尺度图像设置下,PSGAN 在生成具有精细空间细节和高保真光谱信息的高质量全色锐化图像方面优于许多流行的全色锐化方法，

根据他们的实验。此外,作者发现双流架构通常比堆叠更可取,并且批量标准化层和自注意力模块在泛锐化中是不可取的。Pan-GAN[109]使用一个生成器和两个鉴别器来执行全色锐化。

生成器基于 PNN[33]架构,但生成器中的图像比例在不同层中保持相同。光谱和空间鉴别器在结构上相似,但输入不同。

生成的 HRMS 图像或内插的 LRMS 图像被馈送到光谱鉴别器中。原始全色图像或生成的 HRMS 图像沿通道维度平均池化后生成的单通道图像是空间鉴别器的输入。去雾和恢复:边缘锐化循环一致对抗网络 (ES-CCGAN)[64]是一种基于 GAN 的无监督遥感图像去雾方法,基于 CycleGAN[197]。作者使用未配对的图像到图像转换技术来执行图像去雾。ES-CCGAN 包括两个生成器网络和两个判别网络。生成器使用 DenseNet[67]块而不是 ResNet[59]块来生成具有大量纹理信息的去雾遥感图像。除了对抗性损失、循环一致性损失和循环感知一致性损失外,还设计了一个边缘锐化损失来恢复图像中的清晰边缘。此外,为了保留轮廓信息,使用遥感图像数据重新训练 VGG16[146]网络以评估感知损失。为了解决缺乏清晰图像和相应雾度图像对来训练模型的问题,Sun等人[152]提出了一种结合两个 GAN 的级联方法。学习雾化 GAN (UGAN)学习使用不成对的清晰和雾化图像集来雾化遥感图像。然后,UGAN 引导学习去雾 GAN (PAGAN)学习如何对 UGAN 雾化图像进行去雾。王等人[169]开发了图像去斑生成对抗网络 (ID-GAN)来恢复有斑点的合成孔径雷达 (SAR)图像。他们提出的方法使用生成器的编码器-解码器类型架构,通过将噪声图像作为输入来执行图像去斑。鉴别器遵循标准布局,具有一系列卷积、批量归一化和 ReLU 层、sigmoid 函数来区分真实图像和合成图像。作者使用了一个精细的损失函数,它由像素到像素的欧几里得损失、感知损失和对抗性损失组成,所有这些都与适当的权重相结合。

云去除:几位作者使用GAN 去除遥感图像中的云污染 ([147],[97],[128],[175])。CLOUD-GAN[147]可以将多云图像转换为无云可见范围图像。CLOUD-GAN 的功能类似于具有两个生成器和两个鉴别器的 CycleGAN[197]。作者使用 LSGAN[111]训练方法,因为与常规 GAN 相比,它已被证明可以生成更高质量的图像,并且学习过程更加稳定。对于多光谱图像中的薄云去除,Li et al.[97]提出了一种新的半监督方法,称为 CR-GAN-PM,它结合了生成对抗网络和云失真的物理模型。CR-GAN-PM 中有三个网络:提取网络、去除网络和判别网络。GAN 架构由去除网络和判别网络组成。对抗性损失、重建损失、相关损失和优化损失的组合用于训练 CR-GAN-PM。

4.7 材料科学

GAN 在材料科学中有着广泛的应用。GAN 可用于处理各种材料科学挑战,例如微观和晶体结构的生成和设计、复杂结构材料的设计、

提交给 ACM 的手稿

表 8. 遥感应用

遥感应用	GAN 模型
数据生成或扩充	MARTA GAN[105],MSG-ProGAN[120]
超分辨率	HRPGAN[151],D-SRGAN[28]
全色锐化	PSGAN [107],PAN-GAN [109]
除雾和恢复	ES-CCGAN [64],ID-GAN [169]、Sun 等人 [152]
云清除	CLOUD-GAN[147],CR-GAN-PM[97]

无机材料设计、虚拟微结构设计和超孔材料吸声拓扑设计。

辛格等人[148]开发了用于合成二进制微结构图像的物理感知 GAN 模型。作者使用了三个模型来完成这项任务。第一个模型是 WGAN-GP[52]。第二种方法用不变性检查器代替了 GAN 中通常的鉴别器,它明确地强制执行已知的物理不变性。第三个模型结合了前两个模型,重新创建了符合显式物理不变性和源自图像数据的隐式限制的微结构。杨等人[181]提出了一种基于 GAN 的微结构材料设计框架。贝叶斯优化框架用于通过处理 GAN 生成的潜在变量来获得具有所需材料特性的微观结构。 CrystalGAN[123]是一种基于 GAN 的新型框架,用于生成具有增强域复杂性的化学稳定晶体结构。 CrystalGAN 模型由三个主要部分组成,第一步 GAN、特征转移过程和第二步 GAN 合成。第一步 GAN 类似于跨域 GAN ,并生成混合域的伪二进制样本。

特征转移技术给前一阶段获得的样本生成的数据带来了更大的阶复杂度。最后,第二步 GAN 在遵守几何限制的同时合成三元稳定化合物。金等人[85]提出利用受点云启发的基于坐标的晶体表示来使用生成对抗网络生成晶体结构。他们的 Composition-Conditioned Crystal GAN 可以通过使用 one-hot编码的组成向量调节网络来生成具有所需化学组成的材料。设计复杂的建筑材料具有挑战性,并且受经验丰富的设计师先验知识的影响很大。为了解决这个问题,毛等人[112]成功地使用 GAN 来设计复杂的结构材料。数以百万计的随机生成的结构材料被分类为不同的晶体对称性,用于训练他们的模型。他们提出的模型生成复杂的架构设计,不需要先验知识,并且可以很容易地应用于广泛的应用中。

丹等人。 MatGAN [27]是第一个通过生成假设的无机材料对无机材料设计空间进行有效采样的 GAN 模型。 MatGAN 基于 WGAN[7]可以从现有材料中学习隐含的化学成分规则,从而使它们能够生成假设但化学上合理的分子。胡等人进行了另一项类似的工作[65]他们使用 WGAN[7]生成与训练材料的原子组合一致的假设无机材料。

李等人[94]采用 DCGAN[134]、 CycleGAN[197]和 Pix2Pix[70]生成逼真的虚拟微结构图形图像。 KL-divergence 是一个远低于 0.1 的相似性度量,证实了 GAN 生成的图像和地面实况图像之间的相似性。

Zhang 等人使用了 GAN。[188]极大地加速和改进了吸声介孔材料的拓扑设计。使用有限元法 (FEM) 模拟图像数据来训练模型。这

FEM 模拟和实验评估证实了 GAN 生成设计的质量,证明GAN 能够生成具有令人满意的宽带吸收性能的超多孔材料设计。

表 9. 在材料科学中的应用

在材料科学中的应用	GAN 模型
微观和晶体结构的生成和设计	混合 (WGAN-GP [52] + GIN) [148], GAN + GP 对冲贝叶斯优化框架[181], CrystalGAN[123],成分条件晶体甘 [85]
设计复杂的建筑材料	基于GAN的模型[112]
无机材料设计	基于 MatGAN [27]、 WGAN [7]的模型 [65]
虚拟微结构设计	(DCGAN[134]、 CycleGAN[197]和Pix2Pix[70])[94]
吸声超多孔材料的拓扑设计	基于GAN的模型[188]

4.8 金融

财务数据建模是一个具有挑战性的问题,因为该过程背后存在复杂的统计属性和动态随机因素。许多金融数据是时间序列数据,例如房地产价格和股市指数。它们中的许多都非常昂贵,并且通常没有足够的标记历史数据,这极大地限制了深度神经网络的性能。此外,与性别和图像数据等静态特征不同,时间序列数据在时间上具有很高的时间相关性。当我们对多元时间序列进行建模时,这变得更加复杂,我们需要考虑这些变量在时间上的潜在复杂动态。最近,随着 GAN 在图像和音频任务中的发展和广泛使用,许多研究工作提出在金融领域生成逼真的时间序列合成数据。

Efimov 等人[36]结合条件 GAN (CGAN) 和 Deep Regret Analytic Generate Adversarial Networks (DRAGANs),以高保真度复制三个美国运通数据集。在 DRAGAN的鉴别器损失中添加了一个正则化项,以避免梯度爆炸或梯度消失效应以及稳定收敛。周等人[196]采用 GAN-FD 模型 (一种用于最小化预测误差损失和方向预测损失的 GAN 模型)来预测股票价格。生成器基于 LSTM 层,而鉴别器使用 CNN 层。李等人[96]提出了一个名为 Stock-GAN 的条件 Wasserstein GAN (WGAN)来捕获股票市场订单流的历史依赖性。提议的生成器网络有两个精心设计的特征 (1)近似于证券交易所底层的双重拍卖机制,(2)包括订单簿特征作为条件信息。Wiese 等人[176]介绍使用时间卷积网络(TCN)架构的 Quant GAN,也称为 WaveNet[126]作为生成器。它显示了捕捉长期依赖性的能力,例如标准普尔 500 指数等股票数据中波动性集群的存在。FIN-GAN[155]捕捉金融时间序列的时间结构,从而生成价格回报的主要程式化事实,包括线性不可预测性、肥尾分布、波动率聚类、杠杆效应、粗细波动率相关性和增益/损失不对称。 Leangarun 等人[92]构建 LSTM-GAN 来检测由股价操纵引起的异常交易行为。生成器和判别器的基础架构都是 LSTM。模拟操作案例用于测试目的。该检测系统使用泰国证券交易所 (SET) 的交易数据进行了测试,该数据在检测看不见的市场数据中的拉高和抛售操作方面达到了 68.1% 的准确率。

表 10. 金融应用

金融应用	GAN 模型
财务数据生成	CGAN 和 DRAGANs[36]、FIN-GAN[155]、股票甘 [96]
股市预测	GAN-FD [196],量化 GAN [176]
金融异常检测	LSTM-GANs[92]

4.9 营销

GAN 可用于帮助企业通过合成新颖独特的徽标设计并生成模型的假图像来创建有效的营销工具。

通常设计一个新的标志是一个相当漫长和疲惫的过程,需要设计师大量的时间和精力来满足客户的具体要求。 Sage 等人[139]提出了 iWGAN,这是一个基于 GAN 的框架,用于通过指定形状、颜色等参数虚拟生成无限多种徽标,以促进和加快徽标设计过程。作者提出了聚类 GAN 模型来训练多模态数据。聚类用于稳定 GAN 训练、防止模式崩溃并在未标记的数据集上获得更高质量的样本。 GAN 模型基于 DCGAN[134]和 WGAN-GP[52]模型。

LoGAN[117]或带有梯度惩罚的辅助分类器 Wasserstein 生成对抗神经网络 (AC-WGAN-GP) 基于 ACGAN[124]架构。 LoGAN 可用于生成以十二种预定颜色为条件的徽标。 LoGAN 由生成器、鉴别器和分类网络组成,以帮助鉴别器对徽标进行分类。作者使用 WGAN-GP[52]损失函数来获得更好的训练稳定性,而不是使用 ACGAN 损失。

通过生成合成图像和视频,GAN 可用于替换人的真实图像以用于营销相关的广告,从而缓解与隐私相关的问题。马等[110]提出了 Pose Guided Person Image Generation Network (PG2) 来生成以人的图像和新姿势为条件的任意姿势的人的合成假图像。 PG2使用两阶段过程:阶段 1 姿势整合和阶段 2 图像细化。第 1 阶段基于输入图像和描绘人类整体结构的目标姿势生成粗略输出。第 2 阶段采用 DCGAN[134]模型,并通过对抗训练细化初始结果,从而产生更清晰的图像。

可变形 GANs[145]根据外观和姿势生成人物图像。作者引入了可变形跳跃连接和最近邻损失来解决大的空间变形并修复生成的图像和真实图像之间的错位。宋等人[150]提出了 E2E,它使用 GAN 进行无监督的姿势引导人物图像生成。作者将学习各种姿势下的直接映射的艰巨任务分解为语义解析转换和外观生成以处理其复杂性。

表 11. 营销中的应用

营销中的应用	GAN 模型
徽标生成	iWGAN[139]、LoGAN[117]
模型生成和姿势生成	PG2 [110]、可变形GAN [145]、 E2E[150]

4.10 时装设计

当我们想到 GAN 时,时装设计并不是首先想到的,但是开发服装和服装设计是另一个使用 GAN 的领域 ([81],[106],[186]) 。

基于cGAN[118], Attribute-GAN[106]根据服装属性从一对服装中学习映射。该模型有一个生成器和两个鉴别器。生成器使用 U-Net 架构。一个 PatchGAN[69]鉴别器用于捕获局部高频结构信息,多任务属性分类器鉴别器用于确定生成的假服装图像是否具有预期的真实属性。

袁等人[186]提出了 Design-AttGAN,这是属性 GAN (AttGAN)[60] 的新版本,可根据某些用户定义的属性自动编辑服装图像。改变了 AttGAN 的原始公式以避免属性分类损失和重建损失之间的内在冲突。

表 12. 时装设计中的应用

时装设计中的应用	GAN 模型
服装和服装设计	P-GANs[81],Attribute-GAN[106],设计 AttGAN [186]

4.11 体育

GAN 可用于生成体育文本、增强体育数据以及预测和模拟体育活动,以克服标记数据的缺乏并深入了解运动员的行为模式。

李等人[95]使用 WGAN-GP[52]根据比赛统计数据自动生成体育新闻。他们的 WGAN 模型将分数作为输入,并输出描述一支球队如何击败另一支球队的句子。本文还展示了GAN 在 NLP 领域的潜在应用。

JointsGAN[98]由 Li 等人提出。使用运球动作数据集增强足球视频,以提高运球风格分类模型的准确性。作者使用 Mask R-CNN[57]和 OpenPose[15]构建运球球员的关节模型,作为条件并指导 GAN 模型。使用运球球员的关节模型作为 GAN 的条件,分类的准确率从 88.14% 提高到 89.83%。

Theagarajan 等人[157]使用 GAN 来扩充他们的数据集,为与足球相关的任务构建强大的深度学习分类、对象检测和定位模型。具体来说,他们提出了 Triplet CNN-DCGAN 框架,为训练集增加了更多的可变性,以提高上述模型的泛化能力。基于GAN 的模型由正则化 CNN (即 Triplet CNN)和 DCGAN[134]组成,并使用了 Triplet CNN 的 DCGAN 损失和二元交叉熵损失。

记忆增强半监督生成对抗网络 (MSS-GAN)[39]可用于预测网球中的击球类型和位置。MSS-GAN 受到 SS-GAN[30] 的启发,加上内存模块以增强其能力。感知网络 (PN) 用于将输入图像转换为嵌入,然后将其与来自情景记忆 (EM) 和语义记忆 (SM) 的嵌入相结合,通过响应生成网络 (RGN) 预测下一个镜头。最后,使用 GAN 框架来训练网络,将 RGN 的预测镜头传递给判别器,判别器确定它是否是真实的镜头。 BasketballGAN[63]是一个基于 cGAN[118]和 WGAN[7]的框架,用于根据输入条件 (教练制定的进攻战术)和随机噪声向量生成篮球比赛。通过最小化对抗性损失 (Wasserstein损失 [7])运球损失、防守者损失、传球损失和加速损失来训练网络。

表 13. 运动中的应用

体育应用	GAN 模型
体育文本生成 (NLP 任务)	WGAN-GP [52]基于 BY [95]
体育数据增强	JointsGAN[98]、Triplet CNN-DCGAN[157]
运动动作预测与模拟	MSS-GAN[39]、BasketballGAN[63]

4.12 音乐

由于人类感知对全局结构和精细波形相干性都很敏感,因此音乐或音频合成本质上是一个棘手的深度学习问题。因此,合成音乐需要创建保持全局和局部结构的连贯原始音频波形。 GAN 已被应用于音乐流派融合和音乐生成等任务。

FusionGAN[21]是一个基于 GAN 的无监督音乐流派融合框架。作者提出使用基于多路 GAN 的模型,并利用 Wasserstein 距离度量作为稳定训练的目标函数。

MidiNet[180]是一个基于 CNN-GAN 的模型,用于生成具有多个 MIDI 通道的音乐。该模型使用调节器CNN 通过使用前一个条来调节当前条的生成来对时间依赖性进行建模,为 RNN 提供了强大的替代方案。该模型具有灵活的设计,可以根据输入和规范生成多种音乐类型。董等[34]提出了用于符号音乐生成和伴奏或 MuseGAN的多轨序列生成对抗网络。基于 GAN,MuseGAN 可用于符号多轨音乐生成。董等人[35]通过在生成器的输出层中使用二元神经元 [133] 作为精炼网络,展示了一种基于 GAN 的独特模型,用于生成二值钢琴卷。

与现有方法相比,其具有确定性二元神经元的模型生成的输出具有较少的过度碎片化音符。 GANSYNTH[37],基于 GAN 可以生成高保真和局部连贯的音频。所提出的模型在生成高保真音频方面优于最先进的 WaveNet[162]模型,同时在样本生成方面也快得多。 Tokui[158] 使用 GAN来创建未知风格的逼真节奏模式,这些模式不属于训练数据中任何著名的电子舞曲类型。他们提出的 Creative-GAN 模型使用 Genre Ambiguity Loss 来解决原创性问题。李等人[99]提出了一种基于初始模型的条件生成对抗网络方法 (INCO-GAN) ,它允许自动合成完整的可变长度音乐。他们提出的模型由四个不同的组件组成:条件向量生成器 (CVG) 、基于初始模型的条件 GAN (INCO-GAN) 、时间分布层和初始模型[154]。他们的分析表明,所提出的方法的音乐与人类作曲家创作的音乐非常相似,频率向量之间的余弦相似度高达 0.987。

穆罕默德等人[121]提出了 Transformer-GANs 模型,该模型将 GAN 与 Transformer 相结合,生成高质量和连贯的音乐序列。预训练的 SpanBERT[75]用作判别器,Transformer XL[26]用作生成器。为了训练长序列,作者使用 Gumbel-Softmax 技术[89]来获得采样过程的可微近似并保持合理的内存需求,使用了截断反向传播 (TBPTT) 算法 [153]的变体用于长序列上的梯度传播。

5 GAN 的局限性和未来方向

在本节中,我们将讨论 GAN 遇到的一些问题,尤其是与训练稳定性相关的问题。我们还讨论了一些可以提高 GAN 生产力的前瞻性研究领域。

音乐应用	GAN 模型
音乐流派融合	融合GAN[21]
音乐生成	MidiNet[180]、 MuseGAN[34]、基于二元神经元 WGAN-GP [35]、 GANSYNTH [37]、 Creative-BY [158]、 INCO-GANs[99]、 Transformer-GANs[121]

表 14. 音乐中的应用

5.1 GAN 的局限性

生成对抗网络 (GAN) 因其使用大量未标记数据的能力而引起了广泛关注。尽管在减轻与开发和训练新型 GAN 相关的一些障碍方面取得了巨大进展,但仍有一些障碍需要克服。我们解释了训练 GAN 中一些最典型的障碍,以及一些试图在一定程度上缓解这些问题的建议策略。

(1)模式崩溃 :在大多数情况下,我们希望 GAN 生成范围广泛的输出。例如,在创建人脸照片时,我们希望生成器为生成器的每个随机输入生成具有不同特征的多变面孔。当生成器只能产生一种类型的输出或一小组输出时,就会发生模式崩溃。这可能是由于生成器不断搜索对判别器最有说服力的一种输出,以便轻松欺骗判别器,从而继续生成该一种类型。

已经提出了几种方法来缓解模式崩溃的问题。阿约夫斯基等人。 [7]发现Jensen-Shannon 散度对于测量不相交部分的分布距离并不理想。因此,他们提出使用 Wasserstein 距离来计算生成的数据分布与真实数据分布之间的距离。梅茨等人[115]提出了展开的生成对抗网络,它限制了生成器针对某个判别器过度优化的风险,从而减少了模式崩溃并提高了稳定性。

(2)非收敛性 :虽然 GAN 能够实现纳什均衡[48],但要达到这种均衡并不容易。训练过程需要保持生成器和鉴别器网络之间的平衡和同步以获得最佳性能。此外,只有在凸函数的情况下,梯度下降才能保证纳什均衡。

向鉴别器输入添加噪声和惩罚鉴别器权重 ([6]、 [138])是作者试图用来提高 GAN 收敛性的两种正则化技术。

(3)梯度消失 :如果判别器太好,生成器训练可能会由于梯度消失而失败。
一个非常准确的鉴别器会产生零附近的梯度,向生成器提供的反馈很少,并且会减慢或停止学习。

Goodfellow 等人[48]提出了对 minimax loss 的调整,以防止梯度消失问题。尽管对损失的这种调整缓解了梯度消失问题,但它并不能完全解决问题,导致训练更加不稳定和振荡。 Wasserstein 损失[7]是另一种避免梯度消失的技术,因为它旨在防止梯度消失,即使在鉴别器被训练到最优时也是如此。

5.2 未来方向

尽管 GAN 有一些限制和训练问题,但我们不能忽视它们作为生成模型的巨大潜力。未来研究最重要的领域是在理论方面取得进展,以解决模式崩溃、梯度消失、不收敛和模型崩溃等问题。如第 5.1 节所述,已经提出了改变学习目标、规范目标、训练程序、调整超参数和其他技术来克服上述问题。然而,在大多数情况下,实现这些目标需要在期望的输出和训练稳定性之间进行权衡。因此,该领域的未来研究不应一次解决一个培训问题,而应采用整体方法,以实现理论上的突破,以克服上述挑战。

除了在模型训练过程中克服上述理论方面,Saxena 等人 [143] 突出一些有前景的未来研究方向。(1) 保持高图像质量而不失多样性。(2) 提供更多的理论分析,以更好地理解训练过程中的易处理公式,使训练更加稳定和直接。(3)

改进算法,使训练高效 (4) 结合其他技术,如在线学习、博弈论、等与 GAN。

六、结论

在本文中,我们介绍了最先进的 GAN 模型及其在各个领域的应用。GAN 的流行源于它们能够学习潜在空间和数据空间之间极其非线性相关性。因此,可以使用大量未标记的数据,这些数据仍然对监督学习不开放。我们在本文中讨论了 GAN 的许多方面,包括理论、应用和开放研究主题。我们相信,这项研究将帮助来自各个学科的学术和行业研究人员全面掌握 GAN 及其可能的应用。因此,他们将能够分析 GAN 在其特定任务中的潜在应用。

参考

- [1] Alankrita Aggarwal, Mamta Mittal 和 Gopi Battineni. 2021. 生成对抗网络: 理论和应用概述. 国际的 Journal of Information Management Data Insights 1, 1 (2021), 100004. <https://doi.org/10.1016/j.jjime.2020.100004>
- [2] 桑德拉·艾格纳和马尔科·科尔纳. 2018. FutureGAN: 使用时空 3d 卷积预测视频序列的未来帧在渐进式 GAN 中. [arXiv:1810.01325](https://arxiv.org/abs/1810.01325) [cs.CV]
- [3] Hamed Alqahtani, Manolya Kavakli-Thorne 和 Gulshan Kumar. 2021. 生成对抗网络 (GAN) 的应用: 更新评论. 工程计算方法档案 28, 2 (2021 年 3 月 1 日), 525–552. <https://doi.org/10.1007/s11831-019-09388-y>
- [4] Tileli Amimeur, Jeremy M. Shaver, Randal R. Ketchum, J. Alex Taylor, Rutilio H. Clark, Josh Smith, Danielle Van Citters, Christine C. Siska, Pauline Smidt, Megan Sprague, Bruce A. Kerwin, 和院长佩蒂特. 2020. 使用生成对抗网络设计特征控制的人形抗体发现库. *bioRxiv* (2020). <https://doi.org/10.1101/2020.04.12.024844> [arXiv:https://www.biorxiv.org/content/early/2020/04/13/2020.04.12.024844.full.pdf](https://www.biorxiv.org/content/early/2020/04/13/2020.04.12.024844.full.pdf)
- [5] Namrata Anand 和 Possu Huang. 2018. 蛋白质结构的生成建模. 在神经信息处理系统的进展中, S. Bengio, H. Wallach, H. Larochelle, K. Grauman, N. Cesa-Bianchi 和 R. Garnett (编辑), 卷. 31. Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2018/file/afa299a4d1d8c52e75dd8a24c3ce534f-Paper.pdf>
- [6] Martin Arjovsky 和 Léon Bottou. 2017. 迈向训练生成对抗网络的原则方法. [arXiv:1701.04862](https://arxiv.org/abs/1701.04862) [stat.ML]
- [7] Martin Arjovsky, Soumith Chintala 和 Léon Bottou. 2017. Wasserstein 生成对抗网络. 在第 34 届机器学习国际会议论文集 (机器学习研究论文集, 第 70 卷) 中, Doina Precup 和 Yee Whye Teh (编辑). PMLR, 214–223. <http://proceedings.mlr.press/v70/arjovsky17a.html>
- [8] Karim Armanious, Chenming Jiang, Marc Fischer, Thomas Küstner, Tobias Hepp, Konstantin Nikolaou, Sergios Gatidis 和 Bin Yang. 2020. MedGAN: 使用 GAN 的医学图像翻译. 计算机化医学成像和图形学 79 (2020), 101684. <https://doi.org/10.1016/j.compmedimag.2019.101684>
- [9] Yogesh Balaji, Martin Renqiang Min, Bing Bai, Rama Chellappa 和 Hans Peter Graf. 2019. 用于文本到视频合成的具有判别滤波器生成的条件 GAN. 在第二十八届国际人工智能联合会论文集上, IJCAI-19. 国际人工智能组织联合会议, 1995–2001. <https://doi.org/10.24963/ijcai.2019/276>

[10] Andrew Beers,James M. Brown,Ken Chang,J. Peter Campbell,Susan Ostmo,Michael F. Chiang 和 Jayashree Kalpathy-Cramer. 2018.使用逐渐增长的生成对抗网络进行高分辨率医学图像合成。 CoRR abs/1805.03144 (2018)。 [arXiv:1805.03144](https://arxiv.org/abs/1805.03144) <http://arxiv.org/abs/1805.03144> [11] David Berthelot,Thomas Schumm 和 Luke Metz. 2017. 开始 边界平衡生成对抗网络。 [arXiv:1703.10717](https://arxiv.org/abs/1703.10717) [cs.LG]

[12] Avishek Bhattacharjee,Samik Banerjee 和 Sukhendu Das. 2019. PosIX-GAN:使用 GAN 生成多个姿势以进行姿势不变的人脸识别。在计算机视觉 – ECCV 2018 研讨会中, Laura Leal-Taixé 和 Stefan Roth (Eds.)。 Springer International Publishing, Cham, 427–443。

[13] Prateep Bhattacharjee 和 Sukhendu Das. 2017. 使用深度多阶段生成对抗网络预测视频帧的基于时间相干性的标准。在神经信息处理系统的进展中,J. Guyon,UV Luxburg,S. Bengio,H. Wallach,R. Fergus,S. Vish wanathan 和 R. Garnett (Eds.) ,Vol. 30. Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2017/file/b166b57d195370cd41f80dd29ed523d9-论文.pdf>

[14]安德鲁·布洛克,杰夫·多纳休和凯伦·西蒙扬。 2019. 用于高保真自然图像合成的大规模 GAN 训练。 [arXiv:1809.11096](https://arxiv.org/abs/1809.11096) [cs.LG]

[15]曹哲,吉尼斯·伊达尔戈,托马斯·西蒙,魏施恩和亚瑟·谢赫。 2021. OpenPose:使用部分亲和场的实时多人 2D 姿势估计。 IEEE 模式分析和机器智能汇刊 43, 1 (2021), 172–186。 <https://doi.org/10.1109/TPAMI.2019.2929257> [16]董彻,李嫣然,阿图尔·保罗·雅各布,约书亚·本吉奥,李文杰。 2017. 模式正则化生成对抗网络。 ArXiv abs/1612.02136 (2017 年)。

[17] M. Chen,C. Li,K. Li,H. Zhang 和 X. He. 2018. 用于面部表情合成的双编码器条件 GAN。 2018年第37届中空会议 (CCC)。 9286–9291。 <https://doi.org/10.23919/ChiCC.2018.8483579>

[18] Qi Chen, Qi Wu, Jian Chen, Qingyao Wu, Anton van den Hengel, and Mingkui Tan. 2020. Scripted Video Generation With a Bottom-Up Generative 对抗网络。 IEEE 图像处理汇刊 29 (2020), 7454–7467。 <https://doi.org/10.1109/TIP.2020.3003227>

[19]陈曦,严端,Rein Houthoof,John Schulman,Ilya Sutskever 和 Pieter Abbeel. 2016. InfoGAN:通过信息最大化生成对抗网络的可解释表示学习。 CoRR abs/1606.03657 (2016)。 [arXiv:1606.03657](https://arxiv.org/abs/1606.03657) <http://arxiv.org/abs/1606.03657> [20] Y. Chen, Feng Shi, A. Christodoulou, Zhengwei Zhou, Yibin Xie, and D. Li. 2018. 使用生成的高效和准确的 MRI 超分辨率 对抗网络和 3D 多级密集连接网络。 ArXiv abs/1803.01417 (2018)。

[21] Zhiqian Chen, Chih-Wei Wu, Yen-Cheng Lu, Alexander Lerch, and Chang-Tien Lu. 2017. Learning to Fuse Music Genres with Generative Adversarial 双重学习。 2017 年 IEEE 国际数据挖掘会议 (ICDM)。 817–822。 <https://doi.org/10.1109/ICDM.2017.98>

[22] Yunjey Choi,Min-Je Choi,Munyoung Kim,Jung-Woo Ha,Sunghun Kim 和 Jaegul Choo. 2017. StarGAN 统一生成对抗 多域图像到图像转换的网络。 CoRR abs/1711.09020 (2017)。 [arXiv:1711.09020](https://arxiv.org/abs/1711.09020) <http://arxiv.org/abs/1711.09020>

[23] MJM Chuquicusma,S. Hussein,J. Burt 和 U. Bagci. 2018. 如何用生成对抗网络欺骗放射科医生?用于肺癌诊断的视觉图灵测试。 2018 年 IEEE 第 15 届生物医学 成像国际研讨会 (ISBI 2018)。 240–244。 <https://doi.org/10.1109/ISBI.2018.8363564>

[24] 艾丹·克拉克,杰夫·多纳休和凯伦·西蒙扬。 2019. 复杂数据集上的对抗性视频生成。 [arXiv:1907.06571](https://arxiv.org/abs/1907.06571) [cs.CV]

[25] P. Costa,A. Galdran,M. Meyer,M. Niemeijer,M. Abramoff,AM Mendonça 和 A. Campilho. 2018. 端到端对抗性视网膜图像 合成。 IEEE 医学影像汇刊 37, 3 (2018), 781–791。 <https://doi.org/10.1109/TMI.2017.2759102>

[26]戴子航,杨志林,杨一鸣,J. Carbonell,Quoc V. Le 和 R. Salakhutdinov. 2019. Transformer-XL:超越 a 的注意力语言模型 固定长度上下文。在 ACL 中。

[27]丹雅波,赵勇,李向,李少波,胡明,胡建军。 2020. 生成对抗网络 (GAN) 基于化学成分空间的有效采样,用于无机材料的逆向设计。 npj 计算材料 6,1 (2020 年 6 月 26 日),84。 <https://doi.org/10.1038/s41524-020-00352-0>

[28] Bekir Z. Demiray,Muhammed Sit 和 Ibrahim Demir. 2021. D-SRGAN:具有生成对抗网络的 DEM 超分辨率。序列号 计算机科学 2,1 (2021 年 1 月 20 日),第 48 页。 <https://doi.org/10.1007/s42979-020-00442-2>

[29] Jia Deng, Wei Dong, Richard Socher, Li-Jia Li, Kai Li, and Li Fei-Fei. 2009. ImageNet: A large-scale hierarchical image database. In 2009 IEEE 计算机视觉和模式识别会议。 248–255。 <https://doi.org/10.1109/CVPR.2009.5206848>

[30]艾米莉丹顿,山姆格罗斯和罗伯弗格斯。 2016. 使用上下文条件生成对抗网络的半监督学习。 [arXiv:1611.06430](https://arxiv.org/abs/1611.06430) [cs.CV]

[31] Mohamad Dia,Elodie Savary,Martin Melchior 和 Frederic Courbin. 2019. 使用渐进式 GAN 的银河图像模拟。 [arXiv:1909.12160](https://arxiv.org/abs/1909.12160) [cs.LG]

[32]董超,陈昌来,何凯明,唐晓欧。 2016. 使用深度卷积网络的图像超分辨率。 IEEE汇刊 关于模式分析和机器智能 38, 2 (2016), 295–307。 <https://doi.org/10.1109/TPAMI.2015.2439281>

[33]董超,陈昌来,何凯明,唐晓欧。 2016. 使用深度卷积网络的图像超分辨率。 IEEE汇刊 关于模式分析和机器智能 38, 2 (2016), 295–307。 <https://doi.org/10.1109/TPAMI.2015.2439281>

[34] Hao-Wen Dong, Wen-Yi Hsiao, Li-Chia Yang, and Yi-Hsuan Yang. 2017. MuseGAN: Multi-track Sequential Generative Adversarial Networks for 象征性音乐的产生和伴奏。 [arXiv:1709.06298](https://arxiv.org/abs/1709.06298) [eess.AS]

[35] Hao-Wen Dong 和 Yi-Hsuan Yang. 2018. 用于复调音乐生成的具有二元神经元的卷积生成对抗网络。 在伊斯米尔。

[36] Dmitry Efimov,Di Xu,Luyang Kong,Alexey Nefedov 和 Archana Anandakrishnan。 2020.使用生成对抗网络合成人工金融数据集。 arXiv 预印本 arXiv:2002.02271 (2020)。

[37] Jesse Engel,Kumar Krishna Agrawal,Shuo Chen,Ishaan Gulrajani,Chris Donahue 和 Adam Roberts。 2019. GANSynth:对抗神经音频合成。在国际学习代表大会上。 <https://openreview.net/forum?id=H1xQVn09FX>

[38] Cristóbal Esteban,Stephanie L Hyland 和 Gunnar Rätsch。 2017. 具有循环条件甘斯的实值 (医学)时间序列生成。 arXiv 预印本 arXiv:1706.02633 (2017)。

[39] Tharindu Fernando,Simon Denman,Sridha Sridharan 和 Clinton Fookes。 2020. 用于预测网球下一击球位置的记忆增强深度生成模型。 IEEE 知识与数据工程汇刊 32, 9 (2020), 1785–1797。 <https://doi.org/10.1109/TKDE.2019.2911507>

[40] JG Fujimoto,C. Pitris,SA Boppart 和 ME Brezinski。 2000. 光学相干断层扫描:一种新兴的生物医学成像技术和光学活检.肿瘤 (纽约,纽约)2, 1-2 (2000), 9-25。 <https://doi.org/10.1038/sj.neo.7900071> 10933065[pmid]。

[41]列维 福塞尔和本 莫伊斯。 2019. 打造新世界:具有链式生成对抗的高分辨率合成星系<https://doi.org/10.1093/mnras/stz602> 网络.皇家天文学会月刊 485, 3 (03 2019), 3203–3214。 arXiv:<https://academic.oup.com/mnras/article-pdf/485/3/3203/28221657/stz602.pdf>

[42] Arsham Ghahramani,Fiona M. Watt 和 Nicholas M. Luscombe。 2018. 生成对抗网络模拟基因表达并预测单细胞的扰动。 bioRxiv (2018)。 <https://doi.org/10.1101/262501> arXiv:<https://www.biorxiv.org/content/early/2018/07/30/262501.full.pdf> [43] Nina Glaser,O Ivy Wong,Kevin Schawinski 和 Ce Zhang。 2019. RadioGAN - 具有生成对抗网络的不同无线电调查之间的翻译.皇家天文学会月报 487, 3 (06 2019), 4190–4207。 <https://doi.org/10.1093/mnras/stz1534> arXiv: <https://academic.oup.com/mnras/article-pdf/487/3/4190/28853714/stz1534.pdf>

[44] Harshvardhan GM,Mahendra Kumar Gourisaria,Manjusha Pandey 和 Siddharth Swarup Rautaray。 2020. 机器学习中生成模型的全面调查和分析.计算机科学评论 38 (2020), 100285。 <https://doi.org/10.1016/j.cosrev.2020.100285> [45] Amirata Gohorbani,Vivek Natarajan,David Devoud Coz 和刘元。 2019. DermGAN:用病理学合成临床皮肤图像。 <https://arxiv.org/abs/1911.08716> [46] Peter Goldsborough,Nick Pawlowski,Juan C Caicedo,Shantanu Singh 和 Anne E Carpenter。 2017. CytoGAN:细胞图像的生成建模。 bioRxiv (2017)。 <https://doi.org/10.1101/227645> arXiv:<https://www.biorxiv.org/content/early/2017/12/02/227645.full.pdf> [47]梁 戈诺和周益民。 2019. 回顾:生成对抗网络。 2019年第14届IEEE工业电子会议和应用程序 (ICIEA)。 505–510。 <https://doi.org/10.1109/ICIEA.2019.8833686>

[48] Ian Goodfellow,Jean Pouget-Abadie,Mehdi Mirza,Bing Xu,David Warde-Farley,Sherjil Ozair,Aaron Courville 和 Yoshua Bengio。 2014. 生成对抗网络.在神经信息处理系统的进展中,Z. Ghahramani,M. Welling,C. Cortes,N. Lawrence 和 KQ Weinberger (编辑),卷。 27. Curran Associates, Inc.,2672–2680。

[49] Arthur Gretton,Karsten Borgwardt,Malte J Rasch,Bernhard Scholkopf 和 Alexander J Smola。 2008. 两样本问题的核方法。 arXiv 预印本 arXiv:0805.2368 (2008)。

[50] Yuchong Gu, Zitao Zeng, Haibin Chen, Jun Wei, Yaqin Zhang, Binghui Chen, Yingqin Li, Yujuan Qin, Qing Xie, Zhuoren Jiang, and Yao Lu。 2020. MedSRGAN:使用生成对抗网络的医学图像超分辨率.多媒体工具 and 应用程序 79,29 (2020 年 8 月 1 日), 21815–21840。 <https://doi.org/10.1007/s11042-020-08980-w>

[51] Jie Gui, Zhenan Sun, Yonggang Wen, Dacheng Tao, and Jieping Ye。 2020. A Review on Generative Adversarial Networks: Algorithms, Theory, and 应用程序。 arXiv:2001.06937 [cs.LG]

[52] Ishaan Gulrajani,Faruk Ahmed,Martin Arjovsky,Vincent Dumoulin 和 Aaron Courville。 2017. Wasserstein GAN 的改进训练。 arXiv:1704.00028 [cs.LG]

[53] Ishaan Gulrajani,Faruk Ahmed,Martin Arjovsky,Vincent Dumoulin 和 Aaron C Courville。 2017. Wasserstein GAN 的改进训练.在神经信息处理系统的进展中,J. Guyon,UV Luxburg,S. Bengio,H. Wallach,R. Fergus,S. Vishwanathan 和 R. Garnett (Eds.),Vol. 30. Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2017/file/892c3b1c6dcd52936e27cbd0ff683d6-Paper.pdf> [54]安维塔·古普塔和詹姆斯·邹。 2019. 用于 DNA 的反馈 GAN 优化了蛋白质功能.自然机器智能 1,2 (2019 年 2 月 1 日), 105–111。 <https://doi.org/10.1038/s42256-019-0017-4> [55] Swaminathan Gurumurthy,Ravi Kiran Sarvadevabhatla 和 R. Venkatesh Babu。 2017. DeLiGAN:多样化和有限数据的生成对抗网络.在 2017 年 IEEE 计算机视觉和模式识别会议 (CVPR) 上。 4941–4949。 <https://doi.org/10.1109/CVPR.2017.525> [56]韩立功、罗伯特·F·墨菲和德瓦·拉马南。 2018. 使用监督 GAN 学习组织组织的生成模型。 2018年IEEE

计算机视觉应用冬季会议 (WACV)。 682–690。 <https://doi.org/10.1109/WACV.2018.00080>

[57] Kaiming He,Georgia Gkioxari,Piotr Dollár 和 Ross Girshick。 2017. 面具 R-CNN。 2017年IEEE计算机视觉国际会议 (ICCV)。 2980–2988。 <https://doi.org/10.1109/ICCV.2017.322>

[58] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun。 2015. Deep Residual Learning for Image Recognition. CoRR abs/1512.03385 (2015)。 arXiv:1512.03385 <http://arxiv.org/abs/1512.03385>

[59] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun。 2015. Deep Residual Learning for Image Recognition. arXiv:1512.03385 [cs.CV]

[60] Z. He,W. Zuo,M. Kan,S. Shan 和 X. Chen。 2019. AttGAN:仅通过更改您想要的内容来编辑面部属性。 IEEE交易图像处理 28,11 (2019 年 11 月), 5464–5478。 <https://doi.org/10.1109/TIP.2019.2916751>

- [61] Martin Heusel, Hubert Ramsauer, Thomas Unterthiner, Bernhard Nessler, and Sepp Hochreiter. 2017. 由两个时间尺度更新规则训练的 GAN 收敛到局部纳什均衡。在第 31 届神经信息处理系统国际会议 (美国加利福尼亚州长滩) 的论文集中 (NIPS 17). Curran Associates Inc., Red Hook, NY, USA, 6629–6640.
- [62] 杰弗里·辛顿. 2010. 玻尔兹曼机器. Springer 美国, 马萨诸塞州波士顿, 132–136. https://doi.org/10.1007/978-0-387-30164-8_83 [63] Hsin-Ying Hsieh, Chieh-Yu Chen, Yu-Shuen Wang, and Jung-Hong Chuang. 2019. BasketballGAN: 通过素描生成篮球比赛模拟。在第 27 届 ACM 国际多媒体会议 (法国尼斯) (MM 19) 的论文集中。计算机协会, 纽约, 纽约, 美国, 720–728. <https://doi.org/10.1145/3343031.3351050>
- [64] 胡安娜·谢忠、徐永阳、谢明宇、梁武、邱钦军. 2020. 基于改进的生成对抗网络的高分辨率光学遥感图像的无监督去雾。遥感 12, 24 (2020). <https://doi.org/10.3390/rs12244162> [65] 胡天天, 宋慧, 姜涛, 李少波. 2020. 从生成对抗网络学习无机材料的表示。
- 对称 12, 11 (2020). <https://doi.org/10.3390/sym12111889> [66] 胡志航和 Jason TL Wang. 2019. 一种新型对抗推理框架, 用于具有动作控制的视频预测。2019 年 IEEE/CVF 计算机视觉研讨会国际会议 (ICCVW). 768–772. <https://doi.org/10.1109/ICCVW.2019.00101>
- [67] 高煌、刘庄、劳伦斯·范德迈腾和 Kilian Q. Weinberger. 2017. 密集连接的卷积网络。2017 年 IEEE 计算机视觉和模式识别会议 (CVPR). 2261–2269. <https://doi.org/10.1109/CVPR.2017.243>
- [68] Xun Huang 和 Serge Belongie. 2017. 具有自适应实例规范化的实时任意风格转移。2017 年 IEEE 国际计算机视觉会议 (ICCV). 1510–1519. <https://doi.org/10.1109/ICCV.2017.167>
- [69] 菲利普·伊索拉、朱军艳、周廷辉和阿列克谢·A·埃弗罗斯. 2016. 使用条件对抗网络的图像到图像翻译。心电图绝对 / 1611.07004 (2016). [arXiv:1611.07004](http://arxiv.org/abs/1611.07004) <http://arxiv.org/abs/1611.07004>
- [70] 菲利普·伊索拉、朱军艳、周廷辉和阿列克谢·A·埃弗罗斯. 2017. 带有条件对抗网络的图像到图像翻译。2017 年 IEEE 计算机视觉和模式识别会议 (CVPR). 5967–5976. <https://doi.org/10.1109/CVPR.2017.632>
- [71] Seyed Ali Jalalifar, Hosein Hasani, and Hamid Aghajan. 2018. 使用条件生成对抗的语音驱动面部重演网络。 [arXiv:1803.07461](https://arxiv.org/abs/1803.07461) [cs.CV]
- [72] Hyun-Jin Jeong, Yong-Jae Moon, Eunsu Park, and Harim Lee. 2020. 从同步数据太阳日冕磁场外推与 AI 生成的 Farside. 天体物理学杂志 903, 2 (2020 年 11 月), L25. <https://doi.org/10.3847/2041-8213/abc255>
- [73] 姜玉宁、李金华. 2020. 结合纹理损失的图像超分辨率生成对抗网络。应用科学 10, 5 (2020). <https://doi.org/10.3390/app10051729> [74] Cheng-Bin Jin, Hakil Kim, Mingjie Liu, Wonmo Jung, Seongsu Joo, Eunsik Park, Young Saem Ahn, In Ho Han, Jae Il Lee, and Xuenan Cui. 2019 年。
- 使用配对和非配对数据进行深度 CT 到 MR 合成。传感器 19, 10 (2019). <https://doi.org/10.3390/s19102361>
- [75] Mandar Joshi, Danqi Chen, Yinhan Liu, Daniel S. Weld, Luke Zettlemoyer, and Omer Levy. 2020. SpanBERT: Improving Pre-training by Representing and Predicting Spans. 计算语言学协会会刊 8 (2020), 64–77.
- [76] 詹姆斯·M·乔伊斯. 2011. Kullback-Leibler 分歧。施普林格柏林海德堡。柏林, 海德堡, 720–722. https://doi.org/10.1007/978-3-642-04898-2_327
- [77] 阿尼什·卡内瓦和奥利弗·王. 2020. MSG-GAN: 生成对抗网络的多尺度梯度。 [arXiv:1903.06048](https://arxiv.org/abs/1903.06048) [cs.CV]
- [78] Tero Karras, Timo Aila, Samuli Laine, and Jaakko Lehtinen. 2017. GAN 的逐步发展, 以提高质量、稳定性和变化。CoRR abs/1710.10196 (2017). [arXiv:1710.10196](https://arxiv.org/abs/1710.10196) <http://arxiv.org/abs/1710.10196>
- [79] 特罗·卡拉斯、萨穆利·莱恩和蒂莫·艾拉. 2018. 用于生成对抗网络的基于样式的生成器架构。CoRR abs/1812.04948 (2018 年). [arXiv:1812.04948](https://arxiv.org/abs/1812.04948) <http://arxiv.org/abs/1812.04948>
- [80] Tero Karras, Samuli Laine, Miika Aittala, Janne Hellsten, Jaakko Lehtinen, and Timo Aila. 2020. 分析和提高图像质量风格 GAN。在计算机视觉和模式识别 (CVPR) 的 IEEE/CVF 会议论文集中。
- [81] 加藤夏美、欧根博之、大森小太郎、黄春伟和落合洋一. 2019. 基于 GAN 的服装设计: 图案制作器是您设计服装所需的全部。在 2019 年第 10 届增强型人类国际会议 (法国兰斯) (AH2019) 的论文集中。计算机协会, 纽约, 纽约, 美国, 第 21 条, 7 页. <https://doi.org/10.1145/3311823.3311863>
- [82] Doyeon Kim, Donggyu Joo, and Junmo Kim. 2020. TiVGAN: 使用逐步进化生成器生成文本到图像到视频。IEEE 访问 8 (2020), 153113–153122. <https://doi.org/10.1109/ACCESS.2020.3017881>
- [83] Jiwon Kim, Jung Kwon Lee, and Kyoung Mu Lee. 2016. 使用非常深的卷积网络的精确图像超分辨率。2016 年 IEEE 计算机视觉和模式识别会议 (CVPR). 1646–1654 年. <https://doi.org/10.1109/CVPR.2016.182>
- [84] Jiwon Kim, Jung Kwon Lee, and Kyoung Mu Lee. 2016. 用于图像超分辨率的深度递归卷积网络。2016 年 IEEE 计算机视觉和模式识别会议 (CVPR). 1637–1645 年. <https://doi.org/10.1109/CVPR.2016.181>
- [85] Sungwon Kim, Juhwan Noh, Geun Ho Gu, Alan Aspuru-Guzik, and Yousung Jung. 2020. 用于晶体结构预测的生成对抗网络。ACS 中央科学 6, 8 (2020), 1412–1420. <https://doi.org/10.1021/acscentsci.0c00426> [arXiv:https://doi.org/10.1021/acscentsci.0c00426](https://arxiv.org/abs/1703.05192) [86] Taeksoo Kim, Moonsu Cha, Hyunsoo Kim, Jung Kwon Lee, and Jiwon Kim. 2017. 学习使用生成式发现跨域关系对抗网络。CoRR abs/1703.05192 (2017). [arXiv:1703.05192](https://arxiv.org/abs/1703.05192) <http://arxiv.org/abs/1703.05192>
- [87] Taeyoung Kim, Eunsu Park, Harim Lee, Yong-Jae Moon, Sung-Ho Bae, Daye Lim, Soojeong Jang, Lokwon Kim, Il-Hyun Cho, Myungjin Choi, and Kyung-Suk Cho. 2019. 来自 STEREO/EUVI 数据深度学习分析的太阳远端磁图。自然天文学 3, 5 (2019 年 5 月 1 日), 397–400. <https://doi.org/10.1038/s41550-019-0711-5>

[88] Diederik P Kingma and Max Welling. 2014. 自动编码变分贝叶斯。 [arXiv:1312.6114](#) [stat.ML]

[89] 马特·J·库斯纳和何塞·米格尔·埃尔南德斯-洛巴托。 2016. 具有 Gumbel-softmax 分布的离散元素序列的 GANs。 ArXiv abs/1611.04051 (2016 年)。

[90] ChangHyuk Kwon,Sangjin Park,SooHyun Ko and Jaegyoon Ahn. 2021. 提高样本病原分期的预测准确性
使用 GAN 进行增强。 PLoS ONE 16,4 (2021 年 4 月),e0250458。 <https://doi.org/10.1371/journal.pone.0250458>

[91] Yong-Hoon Kwon 和 Min-Gyu Park. 2019. 使用回顾循环 GAN 预测未来帧。在 2019 年 IEEE/CVF 计算机视觉和模式识别会议 (CVPR) 上。 1811-1820 年。 <https://doi.org/10.1109/CVPR.2019.00191> [92] Teema Leangarun,Poj Tangamchit 和 Suttipong Thajchayapong. 2018. 使用生成对抗网络的股票价格操纵检测。
2018 年 IEEE 计算智能系列研讨会 (SSCI)。 IEEE,2104-2111。

[93] Christian Ledig,Lucas Theis,Ferenc Huszar,Jose Caballero,Andrew Cunningham,Alejandro Acosta,Andrew Aitken,Alykhan Tejani,Johannes Totz,Zehan Wang 和 Wenzhe Shi. 2017. 使用生成对抗网络的逼真的单图像超分辨率。 [arXiv:1609.04802](#) [cs.CV]

[94] Jin-Woong Lee,Nam Hoon Goo,Woon Bae Park,Myungho Pyo 和 Kee-Sun Sohn. 2021 年。 虚拟微结构设计<https://doi.org/10.1002/eng2.12274>
用于使用生成对抗网络的钢材。 [arXiv:https://](#) 工程报告 3, 1 (2021), e12274。
<https://doi.org/10.1002/eng2.12274> [95]李长亮,苏一新,季琦,肖敏. 2019. 使用 GAN 从现场比赛统计中生成体育新闻。在认知计算 - ICCCI 2019, Ruifeng Xu,Jianzong Wang 和 Liang-Jie Zhang (主编)。施普林格国际出版社,Cham,102-116。

[96]李俊一,王欣彤,林耀阳,阿鲁内什·辛哈和迈克尔·威尔曼. 2020. 生成现实的股票市场订单流。在 AAAI 人工智能会议论文集上,卷。 34. 727-734。

[97]李军,吴兆聪,胡忠文,张家琪,李明亮,卢默,马蒂厄·莫里尼尔. 2020. 基于生成对抗网络和云畸变物理模型的光学遥感图像中薄云去除。 ISPRS 摄影测量与遥感杂志 166 (2020), 373-389。 <https://doi.org/10.1016/j.isprsjprs.2020.06.021>

[98]李润泽和比尔巴努. 2019. 带有增强运球能量图像的足球视频的细粒度视觉运球风格分析。在 2019 年 IEEE/CVF 计算机视觉和模式识别研讨会 (CVPRW) 会议上。 2439-2447。 <https://doi.org/10.1109/CVPRW.2019.00299> [99]李书玉,宋云希. 2021. INCO-GAN:基于 Inception 模型的条件 GAN 的可变长度音乐生成方法。
数学 9, 4 (2021)。 <https://doi.org/10.3390/math9040387> [100]李婷
婷,钱瑞禾,董超,刘思,琼岩,朱文武,梁琳. 2018. BeautyGAN:使用深度生成对抗网络的实例级面部化妆转移。在第 26 届 ACM 国际多媒体会议 (大韩民国首尔) (MM 18) 论文集上。计算机协会,纽约,纽约,美国,645-653。 <https://doi.org/10.1145/3240508.3240618>

[101] Wenbo Li, Kun Zhou, Lu Qi, Liying Lu, Nianjuan Jiang, Jiangbo Lu, and Jiaya Jia. 2021. Best-Buddy GANs for Highly Detailed Image Super-Resolution. [arXiv:2103.15295](#) [eess.IV]

[102] Yitong Li, Zhe Gan, Yelong Shen, Jingjie Liu, Yu Cheng, Yuxin Wu, Lawrence Carin, David Carlson, and Jianfeng Gao. 2019. StoryGAN: A Sequential Conditional GAN for Story Visualization. In 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 6322-6331. <https://doi.org/10.1109/CVPR.2019.00649> [103] Yitong Li, Martin Renqiang Min, Dinghan Shen, David Carlson, and Lawrence Carin. 2017. Video Generation From Text. [arXiv:1710.00421](#) [cs.MM]

[104]梁晓丹,李丽莎,戴伟和 Eric P. Xing. 2017. 用于未来流嵌入式视频预测的双运动 GAN。 2017 年 IEEE 国际计算机视觉会议 (ICCV)。 1762-1770 年。 <https://doi.org/10.1109/ICCV.2017.194>

[105] Daoyu Lin, Kun Fu, Yang Wang, Guangluan Xu, and Xian Sun. 2017. MARTA GANs: Unsupervised Representation Learning for Remote Sensing Image Classification. IEEE 地球科学和遥感快报 14, 11 (2017), 2092-2096。 <https://doi.org/10.1109/LGRS.2017.2752750>

[106] Linlin Liu, Haijun Zhang, Yuzhu Ji, and Q.M. Jonathan Wu. 2019. Toward AI fashion design: An Attribute-GAN model for clothing match. 神经计算 341 (2019), 156-167。 <https://doi.org/10.1016/j.neucom.2019.03.011>

[107] Xiangyu Liu, Yunhong Wang, and Qingjie Liu. 2018. Psgan: A Generative Adversarial Network for Remote Sensing Image Pan-Sharpener. In 2018 第 25 届 IEEE 图像处理国际会议 (ICIP)。 873-877。 <https://doi.org/10.1109/ICIP.2018.8451049>

[108]陆超超,Michael Hirsch 和 Bernhard Schölkopf. 2017. 用于视频预测的灵活时空网络。在 2017 年 IEEE 会议上
计算机视觉和模式识别 (CVPR)。 2137-2145。 <https://doi.org/10.1109/CVPR.2017.230>

[109] Jiayi Ma, Wei Yu, Chen Chen, Pengwei Liang, Xiaojie Guo, and Junjun Jiang. 2020. Pan-GAN: An unsupervised pan-sharpening method for remote sensing image fusion.信息融合 62 (2020), 110-120。 <https://doi.org/10.1016/j.inffus.2020.04.006>

[110]马丽倩,徐佳,孙倩茹,Bernt Schiele,Tinne Tuytelaars 和 Luc Van Gool. 2017. 姿势引导人物图像生成。在神经信息处理系统的进展中 J. Guyon,U.V. Luxburg,S. Bengio,H. Wallach,R. Fergus,S. Vishwanathan 和 R. Garnett (Eds.), Vol. 30. Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2017/file/34ed066df378efacc9b924ec161e7639-Paper.pdf>

[111]毛旭东,李庆,谢浩然,雷蒙德 YK Lau,王振和斯蒂芬·保罗·斯莫利。 2017. 最小二乘生成对抗网络。
2017 年 IEEE 计算机视觉国际会议 (ICCV)。 2813-2821。 <https://doi.org/10.1109/ICCV.2017.304>

[112]毛云伟,齐和,赵宣和. 2020. 设计具有生成对抗网络的复杂架构材料。科学进步 6 (2020 年)。

[113] Mohamed Marouf,Pierre Machart,Vikas Bansal,Christoph Kilian,Daniel S. Magruder,Christian F. Krebs 和 Stefan Bonn. 2020.使用生成对抗网络实现单细胞 RNA-seq 数据的计算机生成和增强。自然通讯 11, 1 (2020 年 1 月 9 日), 166。

<https://doi.org/10.1038/s41467-019-14018-z>

[114]迈克尔·马蒂厄、卡米尔·库普里和扬·勒昆。2016。超越均方误差的深度多尺度视频预测。 [arXiv:1511.05440](#) [cs.LG]

[115] 卢克·梅斯、本·普尔、大卫·普福和贾沙·索尔·迪克斯坦。2017。展开的生成对抗网络。 [arXiv:1611.02163](#) [cs.LG]

[116]路易斯·米德尔、克里斯托夫·帕姆和马吕斯·厄德特。2019。使用GAN合成医学图像。在医学成像和基于临床图像的程序中安全利用机器学习的不确定性中,Hayit Greenspan、Ryutaro Tanno,Marius Erdt,Tal Arbel,Christian Baumgartner、Adrian Dalca,Carole H. Sudre,William M. Wells,Klaus Drechsler,Marius George Linguraru、Cristina Oyarzun Laura,Raj Shekhar,Stefan Wesarg和Miguel Ángel González Ballester (Eds.)。Springer International Publishing, Cham, 125–134。

[117] Ajkel Mino and Gerasimos Spanakis。2018。LoGAN:使用以颜色为条件的生成对抗神经网络生成微标。2018年第17届IEEE机器学习与应用国际会议 (ICMLA)。965–970。 <https://doi.org/10.1109/ICMLA.2018.00157>

[118] 迈赫迪·米尔扎和西蒙·奥辛德罗。2014。条件生成对抗网络。 [arXiv:1411.1784](#) [cs.LG]

[119] 奥洛夫·莫格伦。2016。C-RNN-GAN:具有对抗性训练的连续递归神经网络。arXiv 预印本 arXiv:1611.09904 (2016)。

[120] Tharun Mohandoss,Aditya Kulkarni,Daniel Northrup,Ernest Mwebaze and Hamed Alemohammad。2020。从 Sentinel-2 生成合成多光谱卫星图像。 [arXiv:2012.03108](#) [cs.CV]

[121] Aashiq Muhamed,L. Li,Xingjian Shi,Suri Yaddanapudi,Wayne Chi,Dylan Jackson,Rahul Suresh,Zachary Chase Lipton 和 Alex Smola。2021 年。使用 Transformer-GAN 生成符号音乐。在 AAAI。

[122] Tomoyuki Nagasawa,Takanori Sato,Isao Nambu 和 Yasuhiro Wada。2020。fNIRS-GANs:使用生成对抗网络的数据增强,用于从功能性近红外光谱中对运动任务进行分类。神经工程杂志 17, 1 (2020 年 2 月),016068,https : //doi.org/10.1088/1741-2552/ab6cb9

[123]阿斯玛·努伊拉、娜塔莉亚·索科洛夫斯卡和让-克劳德·克里维洛。2019。CrystalGAN:学习用生成式发现晶体结构对抗网络。 [arXiv:1810.11203](#) [cs.LG]

[124]奥古斯都·奥德纳、克里斯托弗·奥拉和乔纳森·施伦斯。2017。使用辅助分类器 GAN 进行条件图像合成。在第 34 届机器学习国际会议论文集 (机器学习研究论文集,第 70 卷)中,Doina Precup 和 Yee Whye Teh (编辑)。PMLR,2642-2651。 <http://proceedings.mlr.press/v70/odena17a.html>

[125] Katsunori Ohnishi,Shohei Yamamoto,Yoshitaka Ushiku 和 Tatsuya Harada。2017。来自正交信息的分层视频生成:光流和纹理。CoRR abs/1711.09618 (2017)。 [arXiv:1711.09618](#) <http://arxiv.org/abs/1711.09618>

[126] Aaron van den Oord,Sander Dieleman,Heiga Zen,Karen Simonyan,Oriol Vinyals,Alex Graves,Nal Kalchbrenner,Andrew Senior 和 Koray Kavukcuoglu。2016。Wavenet:原始音频的生成模型。arXiv 预印本 arXiv:1609.03499 (2016)。

[127] Anton Osokin,Anatole Chessel,Rafael E. Carazo Salas 和 Federico Vaggi。2017。用于生物图像合成的 GAN。在 ICCV 2017 - IEEE 计算机视觉国际会议。意大利威尼斯。 <https://hal.archives-ouvertes.fr/hal-01611692>

[128] 恒潘。2020。通过空间注意生成对抗网络对遥感图像进行云去除。 [arXiv:2009.13015](#) [eess.IV]

[129] Eunsu Park,Yong-Jae Moon,Jin-Yi Lee,Rok-Soon Kim,Harim Lee,Daye Lim,Gyungin Shin 和 Taeyoung Kim。2019。通过深度学习从 SDO/HMI 磁图中生成太阳 UV 和 EUV 图像。天体物理学杂志 884,1 (2019 年 10 月),L23。 <https://doi.org/10.3847/2041-8213/ab46bb>

[130] Jinhee Park,Hyerin Kim,Jaekwang Kim 和 Mookyoung Cheon。2020。生成对抗网络在 RNA seq 分析中的实际应用,以预测阿尔茨海默病的分子进展。PLOS 计算生物学 16,7 (2020 年 7 月 24 日),e1008099-e1008099。 <https://doi.org/10.1371/journal.pcbi.1008099> 32706788[pmid]。

[131] Guim Perarnau,Joost van de Weijer,Bogdan Raducanu 和 Jose M. Álvarez。2016。用于图像编辑的可逆条件 GAN。 [arXiv:1611.06355](#) [cs.CV]

[132]埃斯特班·皮亚琴蒂诺、阿尔瓦罗·瓜尔纳和塞西利奥·安吉洛。2021。使用 GAN 生成合成心电图以匿名化医疗保健数据。电子学 10, 4 (2021)。 <https://doi.org/10.3390/electronics10040389>

[133] R2RT。[未]。Tensorflow 中的二元随机神经元。 <https://r2rt.com/binary-stochastic-neurons-in-tensorflow.html> [134]亚历克·拉德福、卢克·梅茨和苏米恩·坎塔拉。2016。具有深度卷积生成对抗的无监督表示学习网络。 [arXiv:1511.06434](#) [cs.LG]

[135] Vishnu B. Raj 和 K Hareesh。2020。生成对抗网络回顾。2020年通信与信号国际会议处理 (ICCSP)。0479–0482。 <https://doi.org/10.1109/ICCSP48568.2020.9182058>

[136] Donatas Repecka,Vykintas Jauniskis,Laurynas Karpus,Elzbieta Rembeza,Irmantas Rokaitis,Jan Zrimec,Simona Poviloniene,Audrius Laurynenas,Sandra Viknander,Wissam Abuajwa,Otto Savolainen,Rolandas Meskys,Martin KM Engqvist 和 Alekse。2021。使用生成对抗网络扩展功能蛋白质序列空间。自然机器学习 3,4 (2021 年 4 月 1 日),324–333。 [HTTPS: //doi.org/10.1038/s42256-021-00310-5](https://doi.org/10.1038/s42256-021-00310-5)

[137]奥拉夫·罗内伯格、菲利普·菲舍尔和托马斯·布罗克斯。2015。U-Net:用于生物医学图像分割的卷积网络。在医学图像计算和计算机辅助干预 - MICCAI 2015,Nassir Navab、Joachim Hornegger,William M. Wells 和 Alejandro F. Frangi (编辑)。Springer International Publishing, Cham, 234–241。

[138]凯文·罗斯、奥雷连·卢奇、塞巴斯蒂安·诺沃津和托马斯·霍夫曼。2017。通过正则化稳定生成对抗网络的训练。 [arXiv:1705.09367](#) [cs.LG]

[139]亚历山大·萨奇、拉杜·蒂莫夫特、埃里库斯·阿古斯松和卢克·范古尔。2018。使用聚类生成对抗网络进行微标合成和操作。在 2018 年 IEEE/CVF 计算机视觉和模式识别会议上。5879–5888。 <https://doi.org/10.1109/CVPR.2018.00616>

提交给 ACM 的手稿

[140]斋藤正树,松本荣一和斋藤俊太。 2017. 具有奇异值裁剪的时间生成对抗网络。 <https://doi.org/10.1109/ICCV.2017.308>

[141] Tim Salimans,Jan Goodfellow,Wojciech Zaremba,Vicki Cheung,Alec Radford,Xi Chen 和 Xi Chen。 2016. 训练GAN 的改进技术。在神经信息处理系统的进展中,D. Lee,M. Sugiyama,U. Luxburg,I. Guyon 和 R. Garnett (主编) ,卷。 29. Curran Associates, Inc. <https://proceedings.neurips.cc/paper/2016/file/8a3363abe792db2d8761d6403605aeb7-Paper.pdf>

[142] Veit Sandfort,Ke Yan,Perry J. Pickhardt 和 Ronald M. Summers。 2019. 使用生成对抗网络 (CycleGAN) 进行数据增强以提高 CT 分割任务的泛化性。科学报告 9,1 (2019 年 11 月 15 日) ,16884。<https://doi.org/10.1038/s41598-019-52737-x> [143] Divya Saxena 和曹建农。 2021. 生成对抗网络 (GAN) 的挑战、解决方案和未来方向。ACM 计算调查 (CSUR) 54, 3 (2021), 1-42。

[144] Gyungin Shin,Yong-Jae Moon,Eunsu Park,Hyun-Jin Jeong,Harim Lee 和 Sung-Ho Bae。 2020.通过深度学习从 Ca ii K 图像生成高分辨率太阳伪磁图。天体物理学杂志 895,1 (2020 年 5 月) ,L16。 <https://doi.org/10.3847/2041-8213/ab9085> [145] Aliaksandr Siarohin,E. Sangineto,Stéphane Lathuilière 和 N. Sebe。 2018. 用于基于姿势的人体图像生成的可变形 GAN。 2018 IEEE/CVF 计算机视觉和模式识别会议 (2018 年) ,3408-3416。

[146]凯伦西蒙扬和安德鲁齐瑟曼。 2015. 用于大规模图像识别的非常深的卷积网络。 [arXiv:1409.1556](https://arxiv.org/abs/1409.1556) [cs.CV]

[147] Praveer Singh 和 Nikos Komodakis。 2018. Cloud-Gan:使用循环一致生成对抗网络去除 Sentinel-2 图像的云。在 IGARSS 2018 - 2018 IEEE 国际地球科学和遥感研讨会上。 1772-1775 年。 <https://doi.org/10.1109/IGARSS.2018.8519033>

[148] Rahul Singh,Viraj Shah,B. Pokuri,S. Sarkar,B. Ganapathysubramanian 和 C. Hegde。 2018. 用于创建的物理感知深度生成模型合成微结构。 ArXiv abs/1811.09669 (2018)。

[149]迈克尔 J 史密斯和詹姆斯 E 吉奇。 2019. 生成深场:通过深度学习任意大小、随机合成天文图像。皇家天文学会月刊 490, 4 (10 2019), 4985-4990。 <https://doi.org/10.1093/mnras/stz2886> arXiv:<https://academic.oup.com/mnras/article-pdf/490/4/4985/30656847/stz2886.pdf>

[150] Sijie Song, Wei Zhang, Jiaying Liu, and Tao Mei. 2019. Unsupervised Person Image Generation With Semantic Parsing Transformation. In IEEE/CVF 计算机视觉和模式识别会议论文集 (CVPR)。

[151] Hai Sun, Ping Wang, Yifan Chang, Li Qi, Hailei Wang, Dan Xiao, Cheng Zhong, Xuelian Wu, Wenbo Li, and Bingyu Sun。 2020. HRPGAN: A GAN-based Model to Generate High-resolution Remote Sensing Images. IOP Conference Series: Earth and Environmental Science 428 (jan 2020), 012060. <https://doi.org/10.1088/1755-1315/428/1/012060>

[152]孙小,徐进东。 2020. 基于级联生成对抗网络的遥感图像去雾算法。 2020年第13届图像与信号处理、生物医学工程与信息学国际大会 (CISP-BMEI) 。 316-321。 <https://doi.org/10.1109/CISP-BMEI51763.2020.9263540>

[153] Ilya Sutskever,Oriol Vinyals 和 Quoc V. Le。 2014. 神经网络的序列到序列学习。在 NIPS 中。

[154] Christian Szegedy,Vincent Vanhoucke,Sergey Ioffe,Jon Shlens 和 Zbigniew Wojna。 2016. 重新思考计算机的初始架构想象。 2016 年 IEEE 计算机视觉和模式识别会议 (CVPR)。 2818-2826。 <https://doi.org/10.1109/CVPR.2016.308>

[155] Shuntaro Takahashi,Yu Chen 和 Kumiko Tanaka-Ishii。 2019. 使用生成对抗网络对金融时间序列进行建模。物理A:统计力学及其应用 527 (2019), 121261。

[156] Hao Tang, Wei Wang, Songsong Wu, Xinya Chen, Dan Xu, Nicu Sebe, and Yan Yan。 2019. Expression Conditional GAN for Facial Expression-to-表达翻译。 CoRR abs/1905.05416 (2019)。 [arXiv:1905.05416](https://arxiv.org/abs/1905.05416) <http://arxiv.org/abs/1905.05416>

[157] Rajkumar Theagarajan 和 Bir Bhanu。 2021. 一种用于从视频中为个人足球运动员生成战术性能统计数据的自动化系统。 IEEE Transactions on Circuits and Systems for Video Technology 31, 2 (2021), 632-646。 <https://doi.org/10.1109/TCSVT.2020.2982580> [158] N.德井。 2020. GAN 能否开创新的电子舞曲流派? -使用具有 Genre Ambiguity 的 GAN 生成新颖的节奏模式损失。 ArXiv abs/2011.13062 (2020)。

[159] Du Tran,Lubomir Bourdev,Rob Fergus,Lorenzo Torresani 和 Manohar Paluri。 2015. 使用 3D 卷积网络学习时空特征。 2015 年 IEEE 计算机视觉国际会议 (ICCV)。 4489-4497。 <https://doi.org/10.1109/ICCV.2015.510> [160]谢尔盖·图利亚科夫、刘明宇、杨晓东和扬·考茨。 2018. MoCoGAN:分解运动和-content 以生成视频。在 IEEE 计算机视觉和模式识别会议 (CVPR)。 1526-1535 年。

[161] Marion Ullmo,Aurélien Decelle 和 Nabila Aghanim。 2020.用生成对抗网络编码大规模宇宙结构。 [arXiv:2011.05244](https://arxiv.org/abs/2011.05244) [天文-ph.CO]

[162] Aaron van den Oord,Sander Dieleman,Heiga Zen,Karen Simonyan,Oriol Vinyals,Alexander Graves,Nal Kalchbrenner,Andrew Senior 和 科雷·卡武克库奥卢。 2016. WaveNet:原始音频的生成模型。在 Arxiv。 <https://arxiv.org/abs/1609.03499>

[163] 塞德里克·维拉尼。 2009. 最佳运输:新。卷。 338.施普林格。

[164] Ruben Villegas,Jimei Yang,Seunghoon Hong,Xunyu Lin 和 Honglak Lee。 2018. 分解自然视频序列的运动和内容预言。 [arXiv:1706.08033](https://arxiv.org/abs/1706.08033) [cs.CV]

[165]卡尔·冯德里克、哈米德·皮尔西亚瓦什和安东尼奥·托拉尔巴。 2016. 使用场景动态生成视频。在第 30 届国际会议上神经信息处理系统会议 (西班牙巴塞罗那) (NIPS 16) 。 Curran Associates Inc., Red Hook, NY, USA, 613-621。

[166]卡尔·冯德里克和安东尼奥·托拉尔巴。 2017. 用对抗变形金刚创造未来。在 2017 年 IEEE 计算机视觉会议和模式识别 (CVPR) 。 2992-3000。 <https://doi.org/10.1109/CVPR.2017.319>

[167] Konstantinos Vougioukas,Stavros Petridis and Maja Pantic. 2019. 具有时间 GAN 的端到端语音驱动的逼真面部动画.在 IEEE/CVF 计算机视觉和模式识别 (CVPR) 研讨会论文集。

[168] Thang Vu,Tung M. Luu and Chang D. Yoo. 2019. 通过相对论生成对抗网络的感知增强图像超分辨率。在计算机视觉 - ECCV 2018 研讨会中,Laura Leal-Taixé and Stefan Roth (Eds.) ,施普林格国际出版社,Cham,98-113。

[169] 王濮阳、张贺和 Vishal M. Patel. 2017. 基于生成对抗网络的斑点 SAR 图像恢复。 2017 年 IEEE 第 7 届多传感器自适应处理计算进展国际研讨会 (CAMSAP)。 1-5。
<https://doi.org/10.1109/CAMSAP.2017.8313133>

[170] Ting-Chun Wang,Ming-Yu Liu,Jun-Yan Zhu,Andrew Tao,Jan Kautz and Bryan Catanzaro. 2018. 条件 GAN 的高分辨率图像合成和语义操作.在 IEEE 计算机视觉和模式识别会议论文集上。

[171]王小倩、卡姆兰·加塞迪·迪扎吉和黄恒。 2018. 用于基因表达推断的条件生成对抗网络。 生物信息学 34, 17 (09 2018), i603–i611。 <https://doi.org/10.1093/bioinformatics/bty563> arXiv:<https://academic.oup.com/bioinformatics/article-pdf/34/17/i603/25702278/bty563.pdf>

[172] Xintao Wang, Ke Yu, Shixiang Wu, Jinjin Gu, Yihao Liu, Chao Dong, Yu Qiao, and Chen Change Loy. 2019. ESRGAN: Enhanced Super-Resolution Generative Adversarial Networks. In Computer Vision – ECCV 2018 Workshops, Laura Leal-Taixé and Stefan Roth (Eds.). Springer International Publishing, Cham, 63–79.

[173]王周,AC Bovik,HR Sheikh 和 EP 西蒙切利。 2004. 图像质量评估:从错误可见性到结构相似性。 IEEE 图像处理交易 13, 4 (2004), 600–612。 <https://doi.org/10.1109/TIP.2003.819861>

[174] Z. Wang,EP Simoncelli and AC Bovik. 2003. 用于图像质量评估的多尺度结构相似性.在三七阿西洛玛信号会议,系统计算机,2003 年,卷。 2. 1398–1402 Vol.2. <https://doi.org/10.1109/ACSSC.2003.1292216>

[175]学文,潘宗旭,胡玉欣,刘家印。 2021. 用于卫星上薄云去除的 YUV 颜色空间中的生成对抗学习意象.遥感 13, 6 (2021)。 <https://doi.org/10.3390/rs13061079>

[176] Magnus Wiese,Robert Knobloch,Ralf Korn 和 Peter Kretschmer。 2020. Quant goose:金融时间序列的深度生成.量化金融 20, 9 (2020), 1419–1440。

[177] Minglei Wu, Yude Bu, Jingchang Pan, Zhenping Yi, and Xiaoming Kong. 2020. Spectra-GANs: A New Automated Denoising Method for Low-S/N 恒星光谱。 IEEE 访问 8 (2020), 107912–107926。 <https://doi.org/10.1109/ACCESS.2020.3000174>

[178] Yungang Xu, Zhigang Zhang, Lei You, Jiajia Liu, Zhiwei Fan, and Xiaobo Zhou. 2020. scIGANs: single-cell RNA-seq imputation using generative adversarial networks. Nucleic Acids Research 48, 15 (06 2020), e85–e85. <https://doi.org/10.1093/nar/gkaa506> arXiv:<https://academic.oup.com/nar/article-pdf/48/15/e85/33697370/gkaa506.pdf>

[179] Koki Yamashita 和康斯坦丁马尔科夫。 2020. 使用超分辨率方法进行医学图像增强.在计算科学 - ICCS 2020 中,Valeria V. Krzhizhanovskaya,Gábor Závodszky,Michael H. Lees,Jack J. Dongarra, Peter MA Sloot,Sérgio Brissos 和 João Teixeira (主编) 。 施普林格国际出版社,Cham,496–508。

[180] Li-Chia Yang,Szu-Yu Chou 和 Yi-Hsuan Yang。 2017. MidiNet:将号域音乐的卷积生成对抗网络一代.在伊斯米尔。

[181]杨子江、李晓琳、L. Catherine Brinson,Alok N. Choudhary,Wei Chen 和 Ankit Agrawal。 2018. 通过深度对抗学习方法设计微结构材料.机械设计杂志 140, 11 (10 2018)。 <https://doi.org/10.1115/1.4041371> arXiv:https://asmedigitalcollection.asme.org/mechanicaldesign/article-pdf/140/11/111416/6375275/md_140_11_111416.pdf 111416。

[182] Raymond A. Yeh,Chen Chen,Teck Yian Lim,Alexander G. Schwing,Mark Hasegawa-Johnson 和 Minh N. Do. 2017.使用深度生成模型进行语义图像修复.在 2017 年 IEEE 计算机视觉和模式识别会议 (CVPR) 上。 6882–6890。 <https://doi.org/10.1109/CVPR.2017.728>

[183] Jinsung Yoon,Daniel Jarrett and Mihaela Van der Schaar. 2019.时间序列生成对抗网络。 (2019) 。

[184] Jiahui Yu, Zhe Lin, Jimei Yang, Xiaohui Shen, Xin Lu, and Thomas S. Huang. 2018. Generative Image Inpainting with Contextual Attention. In 2018 IEEE/CVF 计算机视觉和模式识别会议。 5505–5514。 <https://doi.org/10.1109/CVPR.2018.00577>

[185] Zekuan Yu, Qing Xiang, Jiahao Meng, Caixia Kou, Qiushi Ren, and Yanye Lu. 2019. Retinal image synthesis from multiple-landmarks input with 生成对抗网络.生物医学工程在线 18,1 (2019 年 5 月 21 日) ,62.https://doi.org/10.1186/s12938-019-0682-x

[186] 陈熙元和莫森穆加达姆。 2020. 具有生成对抗网络的服装设计。 arXiv:2007.10947 [cs.CV]

[187]张贺,Vishwanath Sindagi 和 Vishal M. Patel。 2020. 使用条件生成对抗网络进行图像去雨。 IEEE Transactions on Circuits and Systems for Video Technology 30, 11 (2020), 3943–3956。
<https://doi.org/10.1109/TCSVT.2019.2920407> [188]张宏嘉,王阳,赵宏刚,卢克宇,于典龙,温继红。 2021.通过生成对抗网络加速宽带吸声性能超多孔材料的拓扑设计.材料和设计 207 (2021), 109855. <https://doi.org/10.1016/j.matdes.2021.109855>

[189]张涵、徐涛、李洪生、张绍廷、王晓刚、黄晓磊和 Dimitris Metaxas。 2017. StackGAN :使用堆叠生成对抗网络的文本到照片般逼真的图像合成。 2017 年 IEEE 计算机视觉国际会议 (ICCV)。 5908–5916。 <https://doi.org/10.1109/ICCV.2017.629>

[190] Q. Zhang,H. Wang,H. Lu,D. Won and S. Yoon. 2018. 用于组织识别的生成对抗网络的医学图像合成。 2018年IEEE 国际医疗信息学会议 (ICHI)。 IEEE 计算机协会,美国加利福尼亚州洛杉矶阿拉米托斯, 199-207。 <https://doi.org/10.1109/ICHI.2018.00030>

- [191]张庭,田文红,郑庭英,李祖宁,杜雪梅,李凡。 2019. 基于生成对抗网络的逼真人脸图像生成。 2019年第16届小波主动媒体技术与信息处理国际计算机会议。 303–306。
<https://doi.org/10.1109/ICCWAMTIP47768.2019.9067742>
- [192] Zhixin Zhang, Xuhua Pan, Shuhao Jiang, and Peijun Zhao. 2020. High-quality face image generation based on generative adversarial networks. 视觉传达与图像表示杂志 71 (2020), 102719. <https://doi.org/10.1016/j.jvcir.2019.102719> [193]何昭、李慧琪、塞巴斯蒂安·毛雷尔-斯特罗和李成。 2018. 用生成对抗网络合成视网膜和神经元图像。医疗的图像分析 49 (2018), 14–26。 <https://doi.org/10.1016/j.media.2018.07.001>
- [194] Lingling Zhao, Junjie Wang, Long Pang, Yang Liu, and Jun Zhang. 2020. GANsDTA: Predicting Drug-Target Binding Affinity Using GANs. Frontiers in Genetics 10 (2020), 1243. <https://doi.org/10.3389/fgene.2019.01243> [195] Hang Zhou, Yu Liu, Ziwei Liu, Ping Luo, and Xiaogang Wang. 2019. Talking Face Generation by Adversarially Disentangled Audio-Visual Representation. [arXiv:1807.07860](https://arxiv.org/abs/1807.07860) [cs.CV]
- [196]周星宇,潘志松,胡古宇,唐思琪,赵成。 2018. 使用生成对抗网络对高频数据的股市预测。工程数学问题 2018 年 (2018 年)。
- [197] Jun-Yan Zhu, Taesung Park, Phillip Isola 和 Alexei A Efros。 2017. 使用循环一致对抗的未配对图像到图像翻译网络。 In Computer Vision (ICCV), 2017 IEEE 国际会议。
- [198] Xining Zhu, Lin Zhang, Lijun Zhang, Xiao Liu, Ying Shen, and Shengjie Zhao. 2020. GAN-Based Image Super-Resolution with a Novel Quality Loss. 2020 年工程数学问题 (2020 年 2 月 18 日) ,5217429.<https://doi.org/10.1155/2020/5217429>
- [199] Peiye Zhuang, Oluwasanmi Koyejo 和 Alexander G. Schwing。 2021. 享受您的编辑:通过潜在空间进行图像编辑的可控 GAN 导航。 [arXiv:2102.01187](https://arxiv.org/abs/2102.01187) [cs.CV]
- [200] Tiziano Zingales 和 Ingo P. Waldmann。 2018. ExoGAN:使用深度卷积生成对抗检索系外行星大气网络。天文学杂志 156.6 (2018 年 11 月) .268.<https://doi.org/10.3847/1538-3881/aae77c>